

课堂展示与综述报告

数据挖掘前沿专题探究

TA：孙宇涛 潘藤予 刘方舟

2026 秋

目录

1. 任务简介	2
2. 课堂展示	3
3. 综述报告	7
4. 论文列表	9

1. 任务简介

- 本学期引入若干专题，把握大模型与数据挖掘交叉前沿
- **组队** 完成课堂展示：课程 8–15 周，每次课的第 3 小节安排展示
 - Physics of LMs
 - Data Engineering for Pretrain / Post-training / Multimodal / Embodied
 - Self-Supervised Learning
 - 具体周次以教学团队通知为准，排序靠前的论文汇报顺序也会靠前
- **个人** 完成综述报告：期末提交到网络学堂

2.1 课堂展示：准备工作

(1) 组队

- 每组至多 3 人，选出 1 名组长
- **第 5 周周日（10 月 18 日）23:59 前** 完成组队

(2) 选题

- 每组挑选 **一个** 感兴趣的专题
- 在所选专题中挑选 **1–3 篇** 代表性论文进行精读
 - 论文选择范围可在 **专题内** 自行扩展
 - 最终评分与分享论文的数量无关
- **第 7 周周日（11 月 1 日）23:59 前** 确定选择的论文题目

2.1 课堂展示：准备工作

(2.1) 预选

- 每组在问卷中勾选想要分享的论文
 - 自选论文的小组可以填写论文标题，尽早提交问卷供助教审核
- **第 6 周周日（10 月 25 日）23:59 前** 填写问卷
- 助教抽签，在共享文档中公布结果

(2.2) 正选

- 每组在感兴趣的论文前填写自己的临时组名
 - 同时允许小组自选论文，但应在所选专题内，并提供论文标题给助教审核
- **第 7 周周一（10 月 26 日）16:05** 打开共享文档编辑权限

2.2 课堂展示：内容

- 每次课安排 2–3 个组进行展示
- 每组上台展示的人数不限
- **时长**
 - 一堂课两个组讲：每组 18 分钟展示 + 3 分钟互动（问答与讨论）
 - 一堂课三个组讲：每组 12 分钟展示 + 2 分钟互动（问答与讨论）
- **PPT 提交：每组汇报前一天（周四）23:59 前** 提交到网络学堂
 - 在结尾注明小组分工
 - 网络学堂会设置为分组作业，每组提交一次即可
 - 提交后，助教会上传到网络学堂的课程文件中

2.3 课堂展示：评分与考勤

- 课堂发放纸质打分表，除展示组外的同学需为当次两组打分
- **该打分同时计入个人当天考勤**
- 助教亦参与打分，并负责汇总计算总分

3.1 综述报告：主题与范围

- 可以选择提供的任一专题，不一定是所在组课堂展示的专题
- 当某个专题细分为多个小专题时，可以只覆盖小专题中的内容
- 不仅要覆盖所选专题中所有课堂展示内容，还应尽可能全面
- 允许选择规定以外的专题，但应提供初步的论文列表给助教审核
- 字数： ≤ 5000 字（中文），或者 ≤ 3000 词（英文）
- 排版与引用等格式不限

3.2 综述报告：提交方式

- **时间：**第 16 周周日（2027 年 1 月 3 日）23:59 前 提交到网络学堂
- **格式：**要求 PDF 格式，命名为“姓名-学号-专题.pdf”

4.1 论文列表：Physics of LMs 专题

(点击论文标题即可进入对应链接)

[这里](#) 有所有 Parts 的视频和课件

- Physics of Language Models: [Part 1](#), Learning Hierarchical Language Structures
- Physics of Language Models: [Part 2.1](#), Grade-School Math and the Hidden Reasoning Process
- Physics of Language Models: [Part 2.2](#), How to Learn From Mistakes on Grade-School Math Problems
- Physics of Language Models: [Part 3.1](#), Knowledge Storage and Extraction
- Physics of Language Models: [Part 3.2](#), Knowledge Manipulation
- Physics of Language Models: [Part 3.3](#), Knowledge Capacity Scaling Laws
- Physics of Language Models: [Part 4.1](#), Architecture Design and the Magic of Canon Layers

4.2 论文列表：Data Engineering 专题

(点击论文标题即可进入对应链接)

(1) Pretrain

- [\(JMLR'20\)](#) Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer
- [\(NeurIPS'23\)](#) DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining
- [\(NeurIPS'24\)](#) RedPajama: an Open Dataset for Training Large Language Models
- [\(NeurIPS'24\)](#) DataComp-LM: In search of the next generation of training sets for language models
- [\(NeurIPS'24\)](#) The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale
- [\(arXiv'24\)](#) MAP-Neo: Highly Capable and Transparent Bilingual Large Language Model Series
- [\(Huggingface'24\)](#) TxT360: A Top-Quality LLM Pre-training Dataset Requires the Perfect Blend
- [\(ACL'25\)](#) Nemotron-CC: Transforming Common Crawl into a Refined Long-Horizon Pretraining Dataset
- [\(arXiv'25\)](#) Ultra-FineWeb: Efficient Data Filtering and Verification for High-Quality LLM Training Data

4.2 论文列表：Data Engineering 专题

(点击论文标题即可进入对应链接)

(2) Post-training

- [\(arXiv'23\)](#) Textbooks Are All You Need
- [\(ICLR'24\)](#) WizardLM: Empowering large pre-trained language models to follow complex instructions
- [\(arXiv'25\)](#) MiniCPM4: Ultra-Efficient LLMs on End Devices
- [\(arXiv'23\)](#) StarCoder: may the source be with you!
- [\(arXiv'25\)](#) Tongyi DeepResearch Technical Report

4.2 论文列表：Data Engineering 专题

(点击论文标题即可进入对应链接)

(3) Image & Multimodal

- [\(ICLR'24\)](#) Demystifying CLIP Data
- [\(arXiv'25\)](#) TextAtlas5M: A Large-scale Dataset for Dense Text Image Generation
- [\(NeurIPS'23\)](#) DataComp: In search of the next generation of multimodal datasets
- [\(ICLR'25\)](#) OmniCorpus: A Unified Multimodal Corpus of 10 Billion-Level Images Interleaved with Text
- [\(arXiv'26\)](#) Scaling Properties of Text Conditioning in Visual Generation
- [\(arXiv'26\)](#) GPIC: A Giant Permissive Image Corpus for Visual Generation
- [\(arXiv'26\)](#) i1: A Simple and Fully Open Recipe for Strong Text-to-Image Models

4.2 论文列表：Data Engineering 专题

(点击论文标题即可进入对应链接)

(4) Video & Embodied

- [\(ICLR'24\)](#) InternVid: A Large-scale Video-Text Dataset for Multimodal Understanding and Generation
- [\(CVPR'25\)](#) Koala-36M: A Large-scale Video Dataset Improving Consistency between Fine-grained Conditions and Video Content
- [\(ICRA'26\)](#) Scalable Vision-Language-Action Model Pretraining for Robotic Manipulation with Real-Life Human Activity Videos
- [\(arXiv'26\)](#) Cosmos 3: Omnimodal World Models for Physical AI

4.3 论文列表：Self-Supervised 专题

(点击论文标题即可进入对应链接)

(1) 文本

- [\(ICLR'20\)](#) ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators
- [\(EMNLP'21\)](#) SimCSE: Simple Contrastive Learning of Sentence Embeddings
- [\(ACL'21\)](#) DeCLUTR: Deep Contrastive Learning for Unsupervised Textual Representations
- [\(NeurIPS'21\)](#) COCO-LM: Correcting and Contrasting Text Sequences for Language Model Pretraining
- [\(COLM'24\)](#) LLM2Vec: Large Language Models Are Secretly Powerful Text Encoders
- [\(NeurIPS'25\)](#) Nemotron-CLIMB: CLustering-based Iterative Data Mixture Bootstrapping for Language Model Pre-training

4.3 论文列表：Self-Supervised 专题

(点击论文标题即可进入对应链接)

(2) 视觉

- [\(ICML'20\)](#) A Simple Framework for Contrastive Learning of Visual Representations
- [\(CVPR'20\)](#) Momentum Contrast for Unsupervised Visual Representation Learning
- [\(ICCV'21\)](#) Emerging Properties in Self-Supervised Vision Transformers
- [\(CVPR'22\)](#) Masked Autoencoders Are Scalable Vision Learners
- [\(ICLR'22\)](#) BEiT: BERT Pre-Training of Image Transformers
- [\(Meta'25\)](#) DINOv3

(3) 语音

- [\(TASLP'21\)](#) HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units

Thanks

Q & A