

可解释数据挖掘实践：RRL 在分类与回归任务中的应用

数据挖掘课程大作业报告（修订稿）

小组成员及真实分工待填写

摘要

按照课程任务书第 4 节的顺序，本文依次报告数据分析及预处理、模型训练、模型结构优化和对比分析。我们在药物诱导自身免疫预测（DIA，二分类）与鲍鱼环数预测（Abalone，回归）中，以 RRL 规则表征学习器为可解释模型，并各自比较手写线性模型和随机森林。分析从类别比例、中心与离散程度、箱线图、直方图、分位数、相关性及条件趋势出发，再以训练内验证检验处理选择；所有最终比较使用相同的外层五折。DIA 优化 RRL 的阳性 F1 为 0.609，超过随机森林的 0.503，但随机森林阳性 Precision 更高。Abalone 最新纯规则 RRL 两个种子的 RMSE 为 2.194、2.205 环，优于普通 Ridge 的 2.224，仍弱于随机森林的 2.147。混合连续分支曾得到更低误差，但其结果不能冒充纯规则模型的收益。我们同时核查解释与实际预测的一致性，并把规则复杂度和失败对照纳入结论。

目录

1	数据分析及预处理	2
2	模型训练	13
3	模型结构优化	15
4	对比分析	17
	复现索引与成员分工	19

1 数据分析及预处理

1.1 任务定义、原始文件与核对口径

任务书指定 DIA 分类和 Abalone 回归，前者允许合并官方训练集与测试集进行 K 折交叉验证，并明确 SMILES 不必作为模型输入；后者以 Rings 为预测目标，Rings+1.5 仅用于解释年龄。我们保留原始记录，以相同样本索引比较同一任务内的模型，不把两个任务的数值指标混用。

表 1: 原始数据与模型输入。样本数均按本地原始文件核对

任务与来源	规模、目标	使用的输入	原始文件检查
DIA, UCI[2]	597 条; Label=1 有 148 条	两份 CSV 中除标签、SMILES 外的 196 个 RDKit 数值描述 符	无缺失、非有限值、重复行或 重复 SMILES
Abalone, UCI[3]	4177 条; Rings 为 1-29 的整数	Sex 与 7 个测量字段	无缺失、非有限值、重复整行 或重复输入

DIA 的 UCI 网页元数据写有 195 个特征，但下载的训练、测试 CSV 均有 198 列：Label、SMILES 和 196 个描述符；随数据给出的描述符说明也列出 196 个名称。因此以下统计与代码采用实际文件的 196 列口径。Abalone 原始说明指出测量值已经按发布规则缩放；本文图中的数值及导出阈值均以发布值为单位，不把 0.5 直接称为 0.5 毫米。

1.2 DIA：类别、特征类型及中心与离散程度

DIA 阴性 449 条 (75.2%)、阳性 148 条 (24.8%)，见图 1。若始终预测阴性，Accuracy 可达约 75%，却识别不到任何阳性；因此后续采用分层折，并把阳性 Precision、Recall 与 F1 作为主指标。对 196 列按实际观测值作互斥归类：17 列恒为 0，20 列恰为 0/1 二值，76 列为其他整数，83 列至少有一个小数值；没有其他类型。17 个常量不含可区分类别的信息，但为保持原版与优化版 RRL 的输入一致，正式对照没有额外删列。

中心位置按均值、中位数、众数观察；离散程度按标准差、四分位距 $IQR = Q_3 - Q_1$ 及高分位数观察。58 个描述符至少 95% 的观测为 0，许多片段计数的众数和中位数同为 0；Ipc 的中位数约 4.11×10^5 ，最大值却约 3.85×10^{14} 。零值、长尾与大尺度同时存在，说明只报均值会掩盖大部分样本的实际取值区域，也提示随机阈值可能落在几乎没有样本的区间。逐列统计见 results/eda/dia/feature_summary.csv。

1.3 DIA：箱线图、直方图与分位数图

图 2 的上半按

$$D_j = \frac{|\bar{x}_{j,1} - \bar{x}_{j,0}|}{s_j} \quad (1)$$

选出类别均值差相对大的 6 个特征，用来寻找廉价的单特征区分信号；下半从非零比例高、取值数较多的列中选偏度绝对值较小的 6 个作常见分布对照。 D_j 只用于展示，不是正式统计检验。箱体下、中、上三线对应 Q_1 、中位数和 Q_3 ；须延至 $Q_1 - 1.5IQR$ 与 $Q_3 + 1.5IQR$ 内的实际观测，




图 1: DIA 标签数量。阴性约为阳性的三倍，因此总体正确率不能代替少数类识别能力。

单独圆点只是统计离群值。即使上半已经挑了类别差异最大的列，两类箱体仍广泛重叠；下半更对称的描述符也未形成清楚边界。因此后续需要组合条件，而不是把某一列当作可靠诊断规则。

图 3 的上半只取不同取值数大于 10 的非常量列，再按偏度绝对值挑选最强偏态的 6 列；下半复用箱线图的低偏度对照列。每个类别的直方图都归一化为面积约 1，避免阴性样本多而柱高天然更大。Ipc、Kappa3 主体集中在左端，少数极值形成很长右尾；fr_unbrch_alkane、PEOE_VSA5 等列主要取 0。低偏度组更接近连续、单峰的主体，但“低偏度”不等于正态，也不等于能区分类别。

直方图受箱数与边界影响，图 4 用同一组特征的经验分位数补充验证。横轴为样本排序位置，纵轴为对应取值；水平段表示许多样本同值，末端陡升表示少数极端值。fr_unbrch_alkane 的零值平台超过八成，Ipc 只在最高分位陡升；低偏度组则在主体区间更平滑。这些证据支持比较按训练折经验分位数放置 RRL 切点，而不支持在看到全数据图之后直接使用全数据分位数训练。

1.4 DIA：标签关系与描述符冗余

179 个非常量描述符与标签的 Pearson 相关系数绝对值最大仅约 0.216，全部系数约在 -0.13 到 0.22 之间。图 5 列出每一列，而不是只挑与标签相关的 15 列；它和箱线图共同支持“单列线性信号有限”的判断。相关只是探索性描述，不能把全数据标签相关排名直接用于模型筛选，否则测试折标签会参与特征选择。

图 6 左侧是 179 个描述符加标签的 180×180 完整矩阵，局部深色块表明部分分子规模和表面积描述符相关；右侧按全部 $\binom{179}{2} = 15931$ 对描述符汇总绝对相关系数。 $|r|$ 中位数仅 0.068，但仍有 101 对达到 0.95，其中 18 对达到 0.99。少量高相关簇可能产生重复规则；然而绝大多数对弱相关，不能据此大规模删列。散点图另核对过数对完全相同的描述符；正式比较仍保留全部输入，把相关性约简留作候选而非已执行的处理。

图 7 再把相关系数达到 1 的三个具体特征对画成散点，逐点核对它们在本数据中的完全重合。




图 2: DIA 分组箱线图。上: 类别标准化均值差较大的 6 列; 下: 偏度较低的 6 列。两种取样目的不同, 均可见阳性和阴性重叠。




图 3: DIA 分类别概率密度直方图。上为长尾/零值集中的代表, 下为分布较对称的对照; 两类颜色的重叠说明图形形状不能直接当作分类能力。




图 4: DIA 经验分位数。上图与长尾直方图使用同 6 列, 下图是低偏度对照; 末端陡升与零值平台比单一均值更能显示阈值覆盖难题。




图 5: 全部 179 个非常量 DIA 描述符与标签的 Pearson 相关系数（按系数排序）。条形整体较短；完整数值见结果目录的逐列统计表。




图 6: DIA 全部非常量描述符与标签的相关矩阵 (上) 及全部描述符对 $|r|$ 分布 (下)。大图用于看簇, 分布图用于判断簇在全部特征对中的比例。

它证明局部确有重复描述，却不能用三对极端例子代替图 6 的全体相关性统计。




图 7: DIA 三对完全重合的描述符散点。散点是局部核查，全体冗余判断仍按 15931 对的汇总结果。

1.5 Abalone: 字段、数据质量与目标支持度

Abalone 的 Sex 有 M 1528、F 1307、I 1342 条；I 表示幼体，并非人为规定的第三个有序数值。七个测量项包含壳长、垂直壳径、含肉高度以及整体、去壳肉、内脏和干壳重量。环数均值 9.934、中位数及众数为 9、标准差约 3.224；F/I/M 三组平均环数约为 11.129/7.890/10.705。据此保留 Sex 并用 One-Hot 编码，不赋予 1/2/3 的虚假顺序。

质量检查标记 7 条测量疑点：两条高度为 0、一条高度大于最长壳长、四条肉重大于整体重；其中壳重大于整体重与一条高度为 0 的记录重合。图 8 左面标出异常位置；一条 Height=1.130 远高于主要云团。疑点不是已知正确值，故不猜测替换。按原行号每 500 条的平均环数约在 8.66–11.54 间变化，图中间说明直接按原顺序切训练/测试可能产生分布差异；后续采用固定随机打乱的五折。右面显示 Rings ≥ 20 仅 62 条，占 1.48%，提示尾部误差需要单独报告。




图 8: Abalone 测量疑点、原行顺序分块均值与环数支持度。红点是待复核记录，不自动从主实验剔除。

1.6 Abalone: 箱线图、直方图及分位数

图 9 将七个测量值和 Rings 按 M/F/I 分别画箱线图、直方图与分位数图。I 组尺寸和环数整体较低；Rings 的四分位区间为 8–11，箱线图按 $1.5IQR$ 会把 278 个目标观测标作离群，显然不

能把它们全部当作录入错误。高度有 29 个 IQR 离群点，但质量规则只标记少数疑点，说明统计离群与物理不一致是两回事。

重量与环数直方图右尾较长，高环数极少；Height 分位数在末端突跃，呼应个别高值复核。相比之下，Length/Diameter 偏度约 $-0.640/-0.609$ ，重量约 $0.531-0.719$ ，不是所有变量同向强偏态。因此不从图形直接推导全列统一变换或删除群点。主实验保留所有记录；只在训练折移除疑点作敏感性检查，测试折始终完整。




图 9: Abalone 六项 EDA 中的箱线图、直方图和经验分位数（从上至下）。同一字段跨图比较，能区分组间位置变化、右尾和真正稀少的极端观测。

1.7 Abalone: 相关性、散点与条件趋势

图 10 将 Pearson 线性相关与 Spearman 秩相关并列，同时展示各字段与环数的散点。输入之间存在较强共线性：Length/Diameter 的 Pearson $r = 0.987$ ，整体重量/去壳肉重为 0.969。这为手写线性基线提供 L2 正则候选，却不证明删掉其中一列一定更好。壳重与环数的 Spearman 约 0.692、Pearson 约 0.628，说明单调关系比线性关系更强；散点呈上升但纵向分散，同一尺寸可以对应不同环数。




图 10: Abalone 的 Pearson/Spearman 对照（上）和测量值-环数散点（下）。高相关的输入可能使线性系数不稳，而与目标的关系并非单一精确直线。

图 11 在每个 Sex 组内按单个测量值的八分位分箱，点是箱内平均环数，误差棒是箱内环数标准差，不是均值置信区间。成年组的部分肉重曲线趋于平台，壳重则更持续上升；箱内标准差约 1.2-3.8 环，提示尺寸之外还有未观测因素。分箱显示的是关联，不能解释为控制其他测量后的因果效应。它为随机森林和规则模型的非线性比较提供动机，也提示连续趋势可能是纯二值规则回归的难点。




图 11: Abalone 按 Sex 的条件分箱趋势。各组各字段单独分箱；误差棒为箱内标准差。

1.8 由分析到实际预处理

表 2: 数据证据、可能的训练风险与本项目实际决定

任务与证据	风险或待检验假设	实际处理或对照
DIA: 阳性 24.8%	总体正确率掩盖漏检	分层五折，主报阳性 P/R/F1；类别加权只作为搜索候选
DIA: 零值平台与长尾	随机切点可能落入低密度区	比较原始随机阈值与训练折分位数阈值；不在全数据拟合切点
DIA: 17 常量、101 对 $ r \geq 0.95$	冗余可能增大规则搜索空间	正式对照保留全部 196 列，避免与结构消融混淆；删列未作交付处理
Abalone: 无序 Sex、三组环数不同	整数编码带入假次序	One-Hot；基线及 RRL 同源输入
Abalone: 7 条测量疑点	极端值影响尺度与误差	主实验保留；仅训练折去疑点作配对敏感性；不改测试折
Abalone: 强共线、条件平台	线性系数不稳、直线可能欠拟合	手写 Ridge 搜正则强度；RF 与 RRL 检验非线性
Abalone: Rings ≥ 20 仅 62 条	全局误差可能掩盖尾部低估	RMSE、MAE 之外检查尾部 MAE 与有符号偏差

需要缩放的模型仅在当前训练子集估计均值和标准差；Abalone 的目标标准化也只用训练子集统计量，预测后还原为环数。RF 保留原尺度；DIA 不输入 SMILES。原版 RRL 所需的 .data、.info 文件分别由 models/rrl/prepare_dia.py 和 models/rrl/prepare_abalone.py 生成。全数据 EDA 用于提出研究假设，但任何根据标签或分布拟合的阈值、编码、标准化和选参都必须重新在当轮训练数据内完成。

2 模型训练

2.1 训练、验证、测试如何划分

两个任务各有五个固定的外层测试折，同一任务的三类模型使用完全相同的样本索引。DIA 用分层随机五折（随机种子 0）保持各折阳性比例；Abalone 用打乱后的随机五折（随机种子 0）。以 DIA 的第二折为例：先把它完全放下，只用其余四折训练、预处理与选参；选好配置后在这四折全部数据上重新训练，再在第二折评价一次。换到第三折时是重新训练另一个模型，所以第二折在那一轮成为训练数据并不泄漏到“第二折作测试”的模型。

训练集内部还有一层选参划分。DIA 的两个基线在外层训练部分按 80:20 分层切为内部训练/验证集；优化 RRL 对外层训练部分再作分层三折。Abalone 的 Ridge、RF 和最新 RRL 候选都在外层训练部分作三折内部评价；RRL 需要早停时，还只从当前训练子集留出停止验证集，先选轮数再在完整可用训练子集重训。内层决定参数，外层只检验整套“选择 + 重训”流程。折间均值和标准差衡量这五次外部测试结果的变化，不是五份独立新数据，也不是置信区间。

2.2 模型选择与手写实现

表 3: 每个任务的三类模型及承担的比较角色

模型家族	DIA（二分类）	Abalone（回归）
手写线性基线	NumPy 逻辑回归：低复杂度线性概率参照	NumPy Ridge：共线测量下的正则化线性参照
非线性基线	sklearn 随机森林：阈值与交互	sklearn 随机森林：非线性与平台趋势
可解释模型	原版、单项切点修改及联合优化 RRL	回归适配、混合探索及当前纯规则 RRL

手写逻辑回归计算 $p_i = \sigma(w^\top x_i + b)$ ，最小化二元交叉熵加 L2 项；批量梯度由 NumPy 矩阵运算实现，不调用 sklearn 的 LogisticRegression。手写 Ridge 不惩罚截距；令 $\tilde{X}$ 为补上全 1 截距列的训练折设计矩阵、 $D = \text{diag}(0, 1, \dots, 1)$ ，它求解

$$(\tilde{X}^\top \tilde{X} + n\lambda D)\hat{\beta} = \tilde{X}^\top y, \quad (2)$$

实际用 NumPy 最小二乘求解上述方程，而非显式形成逆矩阵；这对应平均平方误差加 $\lambda\|w\|_2^2$ ，且没有调用现成 Ridge 估计器。线性模型系数易检查，但相关输入的单个系数不能解释为稳定的因果效应。随机森林由多棵树平均，能捕捉阈值与交互，不过整体预测不易压缩为少量全局规则。

RRL[1] 先把连续属性转为 0/1 条件，再由 AND/OR 逻辑层产生规则激活 $R_j(x) \in \{0, 1\}$ ，最后用线性输出头组合规则。训练时 NLAF 为离散门提供连续近似，梯度嫁接把硬前向与可导反向连接起来；预测仍执行离散逻辑。分类得到两个 logit 后计算类别概率；回归适配把输出改成一个不经 softmax 的实数，将交叉熵换为 MSE，候选实验还比较 Huber：

$$z_c = b_c + \sum_j a_{cj} R_j(x), \quad \widehat{\text{Rings}} = b + \sum_j a_j R_j(x), \quad L_{\text{MSE}} = \frac{1}{n} \sum_i (\hat{y}_i - y_i)^2. \quad (3)$$

Abalone 的目标只在训练子集标准化，预测与规则权重再换算回原始环数单位；最终预测不取整。保留 AND/OR、NLAF 与梯度嫁接，是“改造 RRL 做回归”而非另用外部回归模型替换它。

2.3 评价指标与选参准则

DIA 的最终分类决策使用统一阈值 0.5，以阳性为关注类：

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}. \quad (4)$$

P 反映报出阳性后的可靠程度， R 反映实际阳性被找到的比例；固定阈值下的 F1 同时约束误报与漏报。阈值若改变，这三个数也会改变，因此不能把固定阈值结果直接解释为所有使用情境都优。DIA 的超参数选择历史上以内层 PR 曲线的平均精度为准；这是训练协议而非本文主展示指标，主结果表只呈现阳性 P/R/F1。

Abalone 在原始环数单位计算

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_i |\hat{y}_i - y_i|, \quad R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (y_i - \bar{y}_{\text{test}})^2}. \quad (5)$$

RMSE 对大误差更敏感，MAE 是平均差几环， R^2 与该测试折的均值预测作对照。内层以 RMSE 选参；测试集目标均值只用于 R^2 定义，绝不进入训练。尾部另报 Rings ≥ 20 的 MAE 与有符号偏差，防止整体均值掩盖高环数低估。

2.4 训练设置、候选范围与第一轮结果

DIA 原始 RRL 使用随机正态切点、5@16 结构、100 轮、batch 32、学习率 0.002、逻辑权重 L2 0.001。手写逻辑回归在 $\lambda \in \{0, 0.001, 0.01, 0.1\}$ 中选择；RF 固定 300 棵树，比较深度 4/8/不限制与叶节点至少 1/5 条。这样的基线搜索比后续 40 组 RRL 搜索小，不能宣称相同计算预算。初始五折中，逻辑回归阳性 F1 为 0.465 ± 0.079 ，RF 为 0.503 ± 0.063 ，原始 RRL 为 0.463 ± 0.057 ；原版规则模型尚未表现出性能优势，构成结构优化的起点。

Abalone 初始 RRL 使用同样的随机切点与 5@16，改为回归头、MSE、batch 128、100 轮、学习率 0.002 和逻辑 L2 0.001。手写 Ridge 比较 $\lambda = 0, 0.001, 0.01, 0.1, 1$ ；RF 首轮固定 150 棵树，比较深度 8/不限制、叶节点至少 1/5/10 条。训练均值预测 RMSE 为 3.224 ± 0.122 ，原始回归 RRL 为 2.473 ± 0.216 ，说明规则有预测信息但明显落后 Ridge 的 2.224 ± 0.136 与 RF 的 2.147 ± 0.039 。这些分数是同一外层五折的均值 $\pm$ 折间样本标准差；训练过程中的最好验证分数并未混入测试表。

3 模型结构优化

3.1 DIA：从阈值覆盖假设到联合优化

EDA 中许多描述符零值集中或尾部极长。原始 RRL 在标准化特征上抽取随机正态切点，可能把有限的五个条件浪费在低密度区。单因素实验只把每列阈值改为当前训练子集的经验分位数

$$c_{jk} = Q_{X_j}^{\text{train}}(k/6), \quad k = 1, \dots, 5; \quad (6)$$

逻辑层、训练轮数、NLAF 与其他显式配置不变。五折阳性 Recall 从 0.418 升至 0.467、F1 从 0.463 升至 0.480。结果与阈值覆盖假设相符，但 F1 增益有限，且分位数版折间波动较大。随机切点路径还会消耗随机数；本项 DIA 实验没有像后来的 Abalone 审计那样核对初始权重逐位一致，因此不能把全部差值严格归因于切点位置。

随后冻结 40 个候选配置：切点为随机、分位数或仅用当前训练子集标签计算的 Gini 下降切点；结构涵盖 3@16 至 10@32 及两层形式，另比较 NLAF 参数、学习率、L2、类别权重、轮数、温度与显式 NOT。每个外层训练折内作三折选择，累计 600 次内层训练和 5 次外层重训。外层第 0、4 折选择监督切点、5@64 与加权；其余三折选择随机切点、5@32 与不加权。联合优化的阳性 F1 达 0.609 ± 0.063 ，Recall 为 0.541 ± 0.063 ，相对原始版改善明显，但不能把联合搜索总收益全归因于分位数。

供后续使用的全数据模型仅按内部验证排名选配置 27：随机切点、5@32、学习率 0.005、无 L2、160 轮、NLAF (0.999, 8, 3)；它不是单项实验的分位数模型。五折 0.609 是“内层搜索-重训-外层评价”流程的成绩，并非该固定配置在独立测试集上的新成绩；精度收益还伴随更高规则复杂度，见第 4 节的结构对照。

3.2 Abalone：由初版失败提出的两条路线

第一轮在纯规则架构中搜索 24 组结构、切点、损失与训练参数，五折 RMSE 从 2.473 降至 2.290，仍不及 Ridge/RF。训练折分位数切点的严格配对对照平均比随机切点低约 0.055 环，五折中四折改善；但检查发现两种切点生成消耗的随机数不同，即使设置相同种子，后续逻辑权重也未必同初值。我们补足随机数消耗并验证初始权重一致：未配对版本 RMSE 为 2.398，配对版本为 2.417。这次审计把“分位数有效”的证据限定为较小且不稳定的改善，没有只挑更好看的版本。仅从训练折删 7 条疑点，平均 RMSE 也略降，但改善主要来自一折，尾部 MAE 反而增加；故主流程继续保留全部记录。

从 EDA 的平滑趋势和初版误差出发，第二轮怀疑“二值规则丢失区间内连续变化”，于是让原数值和 hinge 基函数 $\max(x_k - c, 0)$ 形成并行连续分支，先训练规则，再固定规则并用手写 Ridge 联合拟合两路输出权重：

$$\hat{y} = b + \underbrace{\sum_k v_k x_k + \sum_{k,t} u_{kt} \max(x_k - c_{kt}, 0)}_{\text{连续通路}} + \underbrace{\sum_j a_j R_j(x)}_{\text{规则通路}}. \quad (7)$$

混合模型 RMSE 为 2.145，但去掉规则仅保留分段线性后进一步降至 2.124。因此这一轮找到的是有效的连续预测器，没有证明规则带来增益。第三轮强化 RF 对手，调整规则系数与连续系数的分

组正则、早停和残差规则训练；胜出混合方案 RMSE 为 2.103，扩搜 RF 为 2.148，且匹配去规则对照五折都使误差上升、平均约 0.022 环。残差训练本身不是胜出配置；第四轮更复杂结构也没有超过第三轮。尽管第三轮证明那套混合配置中的规则有边际贡献，它仍不是纯规则 RRL，不应作为本项目规则模型主成绩。

表 4: Abalone 优化的发现-行动-结果链。不同路线的分数不可混称

阶段	观察与假设	检验行动	五折 RMSE 或判断
初版	分类 RRL 需回归适配	单实数头、MSE、固定 5@16	2.473
第一轮	随机切点覆盖与容量可能不足	配对切点、24 组联合搜索	2.417（配对切点）； 2.290（优化）
第二轮	连续趋势被二值化损失	连续分段线性与规则并联、去规则	2.145；去规则 2.124
第三/四轮	规则或可补连续残差	分组正则、早停、残差实验及扩搜 RF	混合 2.103；更复杂第四轮未提升
回归规则主线	混合分支掩盖规则主体	移除连续直连，重新优化纯规则	2.203/2.205；后续 2.194/2.205

3.3 回到纯规则：训练机制与文献启发的结构检验

纯规则主线去掉式 (7) 的连续通路，保留式 (3)。在规则训练后只针对规则激活用 Ridge 重拟合输出系数，这不是额外的原数值预测器；早停依据训练内验证误差选轮数，再在可用训练集重训。此前纯规则版本 RMSE 2.257；新流程两个种子分别为 2.203 和 2.205。配对实验更支持早停，短规则初始化和完整 Sex 词表没有稳定收益。两个种子分别评价单模型，不平均预测。

随后借鉴逻辑网络回归与稀疏规则研究 [4, 5]，检验更有目标信息的切点与持续限制规则长度。训练子集内的单特征回归树产生递归切点；不足 20 个时用分位数补位。连接上限 cap8 在初始化和每个优化步后，使每个 AND/OR 节点最多有 8 条大于 0.5 的硬连接；被压回阈值以下的软权重仍可接受梯度，不是永久剪枝。阈值生成、早停和输出重拟合都只使用当前训练数据；没有引入论文中的端到端阈值学习或软 Top-K。

表 5: Abalone 固定的树切点 × 连接上限对照（外层五折平均；列为两个训练种子）

配置	RMSE 314	RMSE 2718	每节点条件数 314	每节点条件数 2718
分位数参照	2.20848	2.20425	10.47	11.38
仅树切点	2.19519	2.19691	11.20	10.43
仅 cap8	2.19842	2.19770	7.10	6.91
树切点 +cap8	2.18594	2.19522	6.92	7.14

固定组合在两个种子中都小幅降低 RMSE，并将硬连接数约减少 34%/37%；它说明可以缩短规则而不明显损失这套设置的性能。不过正式 12 候选、内层三折 × 双种子选择的流程，两个种子的外层 RMSE 为 2.19420/2.20469：种子 314 相对上一轮约改善 0.009，种子 2718 实质持平。内

层总排名选择更宽的 20@128，全数据交付模型使用分位数切点，没有树切点或 cap。不能把表 5 的短规则复杂度误写成最终模型复杂度。




图 12: 固定对照中的规则长度、多样性与 RMSE。图中的树切点 +cap 收益属于机制实验，不是最终所选 20@128 模型的结构属性。

4 对比分析

4.1 DIA：阳性识别性能及其代价

表 6: DIA 外层五折分类结果 (均值 $\pm$ 折间标准差; 阳性类, 阈值 0.5)

模型	Precision $\uparrow$	Recall $\uparrow$	F1 $\uparrow$
手写逻辑回归	0.548 $\pm$ 0.159	0.411 $\pm$ 0.060	0.465 $\pm$ 0.079
随机森林	0.861 $\pm$ 0.080	0.359 $\pm$ 0.065	0.503 $\pm$ 0.063
原始 RRL	0.520 $\pm$ 0.053	0.418 $\pm$ 0.065	0.463 $\pm$ 0.057
分位数 RRL	0.591 $\pm$ 0.213	0.467 $\pm$ 0.167	0.480 $\pm$ 0.082
联合优化 RRL	0.696 $\pm$ 0.066	0.541 $\pm$ 0.063	0.609 $\pm$ 0.063

原始 RRL 与手写逻辑回归的阳性 F1 接近，表明具有可解释规则本身不保证更准确；单独改切点略有帮助，联合优化才使 F1 达到 0.609。RF 的阳性 Precision 为 0.861，高于优化 RRL 的 0.696，但 Recall 只有 0.359；RRL 的 Recall 为 0.541。若用途是优先筛出可能有风险的候选药物，较高 Recall 有价值，但真实部署必须另定漏检与误报成本，并重新选择阈值。本文只陈述当前数据和固定 0.5 阈值下的比较，不把 F1 优势扩张为全面优于 RF。

4.2 Abalone：回归精度、训练路线与尾部

第一轮优化明显缩小了原始 RRL 与线性基线的差距，但没有超过 Ridge。最新纯规则 RRL 在两种种子下 RMSE 都略好于 Ridge，说明规则组合在当前配置下捕捉到了普通线性模型未完全表达的条件；不过 RF 在 RMSE、MAE 和 R^2 上仍更好。该差距不需隐去：课程要求探索和解释可解释模型，并没有规定它必须胜过每个基线。历史混合模型的 2.103 属于连续通路 + 规则，虽然比 RF 小，却不能填到纯规则 RRL 这一行。

表 7: Abalone 同一外层五折的主要结果 (均值 $\pm$ 折间标准差; 误差单位为环)

模型	RMSE $\downarrow$	MAE $\downarrow$	$R^2 \uparrow$	≥ 20 MAE $\downarrow$
训练均值	3.224 ± 0.122	2.364 ± 0.097	-0.003 ± 0.004	11.692 ± 0.684
手写 Ridge	2.224 ± 0.136	1.587 ± 0.069	0.522 ± 0.038	7.170 ± 0.718
随机森林	2.147 ± 0.039	1.514 ± 0.024	0.554 ± 0.028	7.386 ± 0.632
原始回归 RRL	2.473 ± 0.216	1.756 ± 0.148	0.409 ± 0.072	8.960 ± 1.185
第一轮优化 RRL	2.290 ± 0.055	1.634 ± 0.062	0.493 ± 0.015	8.363 ± 0.613
最新纯规则 RRL, 314	2.194 ± 0.072	1.557 ± 0.041	0.535 ± 0.015	7.805 ± 0.655
最新纯规则 RRL, 2718	2.205 ± 0.072	1.563 ± 0.049	0.530 ± 0.023	8.000 ± 0.848

高环数尾部呈不同排序: Ridge 的 ≥ 20 MAE 约 7.17, 优于 RF 和两种纯规则 RRL。总体 RMSE 最低的模型因此未必在每个子群都最好。图 13 同时展示外层 RMSE 和尾部 MAE; 误差棒是五折间标准差, 而高环数每折只有 9–18 条, 尾部数值波动应谨慎解读。




图 13: Abalone 纯规则选参流程与基线。图中的 Reference 是配对旧配置, Selected 是当前训练内选参流程; 两个种子分别为单模型, 不作集成。

4.3 可理解性、忠实性与结构复杂度

线性模型以系数和截距给出紧凑的加性表达; DIA 逻辑回归的系数描述标准化输入对 log-odds 的贡献, Abalone Ridge 的系数描述在其他输入固定时的线性变化。它们易读, 但难写出交互条件, 且 Abalone 强共线会使单个系数不稳定。随机森林的单棵树可检查, 150/300 棵树的平均却难以形成简短的全局说明。RRL 的一条规则是可执行的真假条件, 输出头把激活规则加权求和; 这种解释与模型结构同源, 而不是事后拟合的替代解释。但规则越多越长, 读者越难在纸面上理解全局行为。

DIA 的 100% 指保存的模型两种前向方式在外层测试样本上给出相同类别, 尚不是重新解析文本规则的端到端数值审计。Abalone 则从完整规则 JSON 读取阈值、连接及输出系数, 独立用 NumPy 布尔运算重新预测; 外层保存预测的最大差约 1.78×10^{-15} 环, 全数据 checkpoint 与 JSON

表 8: 规则结构与忠实性检查。DIA 和 Abalone 的计数口径不同, 不作跨任务大小排名

模型版本	规则/节点	硬连接	忠实性与解释成本
DIA 原始 RRL, 五折均值	约 13.8 条简化规则	约 58.8 条	普通前向与严格离散前向的类别决策一致率 100%
DIA 优化 RRL, 五折均值	约 69.8 条简化规则	约 1806.0 条	类别一致率 100%; 复杂度显著上升
Abalone 最终纯规则模型	256 个原始逻辑节点	2430 条	平均每节点 9.492 个条件; 全精度 JSON 可独立执行

的差为 0。这比只比较模型两种前向更强, 但也只证明逻辑忠实, 不证明用户能轻松理解 256 个节点。

例如 Abalone 最终模型的一条规则要求 $\text{Length} > 0.605$ 、 $\text{Viscera weight} > 0.089$ 、 $\text{Height} \leq 0.2$ 、 $\text{Whole weight} \leq 1.712$; 它在训练数据中的 Support 约 0.216, 输出权重约 -0.141 环。Support 只表示约 21.6% 的训练样本满足该条件, 不是该规则独立预测的准确率; 成立时它只给总和加上 -0.141 环, 其他激活规则和偏置仍同时发挥作用。具体化学或生物机制也不能由这些相关条件直接推出。

4.4 跨任务结论、局限与交付范围

DIA 的难题来自少数阳性、稀疏长尾和弱单列信号, 训练内切点设计与规则组合有机会提高召回; Abalone 的目标沿连续尺寸平滑变化, 纯二值规则更难逼近区间内趋势, 因此 RF 总体更准。两个任务共享 RRL 的逻辑网络思想, 却不要求同一组超参数或相同模型排序。最重要的实验分界是: 结构单项改善不等于联合搜索总收益; 连续通路带来的收益不等于规则收益; 固定短规则对照的收益也不等于最终宽模型使用了该改动。

五折是在本项目数据上的内部评价。多轮实验使用同一数据进行自适应设计, 即便每轮训练内流程没有直接读取自己的测试折, 也不能把后续五折当成全新的外部确认。DIA 未用 SMILES 建立分子图输入; Abalone 的高环数样本极少, 缺少采样地点等变量。当前交付主张是课程范围内的过程、对照、失败检验与忠实规则, 而不是现实部署的有效性证明。

复现索引与成员分工

数据获取入口是 `download_data.py`; EDA 的统计与作图在 `analysis/eda.py`、`analysis/abalone_eda.py`。手写线性模型位于 `models/manual_glm/`, RRL 基础与回归适配位于 `models/rrl/`; DIA 主要入口为 `experiments/run_dia_baselines.py` 和 `models/rrl/optimize_dia.py`, Abalone 最新纯规则入口为 `experiments/abalone_literature.py`。完整逐折预测、搜索、消融、导出规则与审计保存在 `results/dia/`、`results/abalone/`; 本文只选必要图表与数字入正文, 不将所有历史产物塞进课程提交包。报告与完整代码的最小 ZIP 仍需另行在干净目录验收。

小组成员与真实分工: 待成员确认后填写。不根据 Git 作者或文件修改记录推断个人贡献; 正式提交前应补齐此节。

参考文献

- [1] Z. Wang, W. Zhang, N. Liu, and J. Wang, *Learning Interpretable Rules for Scalable Data Representation and Classification*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(2):1121–1133, 2024. DOI: [10.1109/TPAMI.2023.3328881](https://doi.org/10.1109/TPAMI.2023.3328881).
- [2] X. Huang, *Drug Induced Autoimmunity Prediction*, UCI Machine Learning Repository, 2025. https://archive.ics.uci.edu/dataset/1104/drug_induced_autoimmunity_prediction.
- [3] W. Nash, T. Sellers, S. Talbot, A. Cawthorn, and W. Ford, *Abalone*, UCI Machine Learning Repository, 1994. <https://archive.ics.uci.edu/dataset/1/abalone>.
- [4] C. Yue and N. K. Jha, *Learning Interpretable Differentiable Logic Networks for Tabular Regression*, arXiv:2505.23615, 2025. <https://arxiv.org/abs/2505.23615>.
- [5] H. F. Soegeng, S. K. Modi, and T. Peyrin, *TT-Sparse: Learning Sparse Rule Models with Differentiable Truth Tables*, arXiv:2603.07606, 2026. <https://arxiv.org/abs/2603.07606>.