

可解释数据挖掘实践：RRL 在分类与回归任务中的应用

数据挖掘课程大作业报告

摘要

本文完成药物诱导自身免疫预测 (DIA) 和鲍鱼环数预测 (Abalone) 两项任务，依次报告数据分析及预处理、模型训练、模型结构优化和对比分析。每项任务都比较手写线性模型、随机森林和规则表征学习器 RRL。DIA 的 597 条记录中阳性占 24.8%，196 个数值描述符兼有稀疏、长尾和局部高度相关的特点；优化后的 RRL 在外层五折获得阳性 F1 0.609，高于随机森林的 0.503。Abalone 的 4177 条记录呈现连续尺寸趋势、强共线性和稀少的高环数样本；纯规则 RRL 的两个训练种子得到 RMSE 2.194、2.205 环，优于 Ridge 的 2.224 环，随机森林仍以 2.147 环领先。逐轮消融说明：DIA 的主要进步来自规则结构与训练配置的联合选择；Abalone 的连续分支虽能改善预测，却会掩盖规则自身的作用，因此最终回到纯规则主线。报告同时检查规则长度、覆盖率及导出规则与实际预测的一致性。

目录

1	数据分析及预处理	1
2	模型训练	8
3	模型结构优化	11
4	对比分析	13

1 数据分析及预处理

1.1 任务与分析方法

课程任务书要求同时完成 DIA 二分类与 Abalone 回归，并从数据分析出发设计预处理和模型实验。DIA[2] 合并官方训练、测试 CSV 后共有 597 条记录；原文件每行包含 Label、SMILES 和 196 个 RDKit 描述符（数据集来源网站上显示有 195 个 Feature 与实际数据有出入，以实际数据为准），本文预测 Label。Abalone[3] 共有 4177 条记录，以环数 Rings 为目标，输入为 Sex 与七项尺寸、重量测量值；讨论年龄时可用 $\text{Rings} + 1.5$ ，模型直接预测环数。两个数据集均无缺失值。

分析依照课堂介绍的六类工具展开。均值、中位数和众数定位数据中心，标准差及四分位距 $IQR = Q_3 - Q_1$ 描述分散程度；箱线图显示中位数、四分位数和极端观测，直方图显示频数，经验分位数图显示从低到高的取值变化；散点、分箱趋势和相关系数则帮助判断变量间的关系。

1.2 DIA：不平衡、典型分布与长尾

先做一些简单的统计，做出图 1 左侧的频数柱。DIA 的阴性 449 条、阳性 148 条，比例约为 3 : 1。这个检查很简单但是却很重要：即使始终判为阴性，也有约 75.2% 的总体正确率，却找不到一条阳性。因此，后续保持各折类别比例，同时报告总体正确率、两类平均 F1 和阳性识别指标（因为阳性偏少，如果一视同仁对待的话，训出来的模型会天然偏向判阴性）。图 1 右侧选取取值

较平稳的 MolMR 作普通描述符参照，便于和后面的类别差异图比较。按实际观测值分类，196 个描述符中有 17 列常量、20 列严格 0/1、76 列其他整数、83 列浮点数。17 列常量不提供区分信息；主实验保留原输入维度，使原版与优化版 RRL 的比较一致。




图 1: DIA 的类别比例与普通数值描述符示例。箱体上下缘为 Q_1, Q_3 ，中线为中位数；两类 MolMR 的主体区域明显重叠。

MolMR 的两类中位数和箱体几乎重合。箱体上下缘分别是第 25、75 百分位数，须延至 $Q_1 - 1.5IQR$ 、 $Q_3 + 1.5IQR$ 范围内的实际观测。接着我们想知道：从单列中挑出类别差异相对明显的候选，能否只凭这一列区分阳性和阴性？先对每列计算 $D_j = |\bar{x}_{j,1} - \bar{x}_{j,0}|/s_j$ ，其中分子是两类均值之差，分母是该列全体样本的标准差。 D_j 表示两类均值相隔多少个标准差，便于比较量纲不同的描述符；它用于挑选候选，实际重叠程度还要看箱线图。图 2 选取取值较连续的 FractionCSP3 和零值较多的 PEOE_VSA2，两者的 D_j 分别约为 0.304、0.315，在非常量描述符中排第八、第六。它们的阴性、阳性中位数分别为 0.500/0.409 和 4.900/9.589。两类中心确实移动了，但箱体仍大幅重叠；只用单列阈值分类，容易在漏检与误报之间取舍。因此后续让规则组合多个条件，而不依赖单个描述符。




图 2: DIA 两列数值描述符的类别箱线图。FractionCSP3 展示较连续的常见取值，PEOE_VSA2 展示更明显的类别位移；为看清箱体，图中不画离群点，统计时仍保留全部记录。

接着检查取值尺度，原因是稀疏和长尾可能让 RRL 的随机切点落在几乎没有样本的位置。58 列描述符至少 95% 的值为零，Ipc 的中位数约 4.11×10^5 、最大值约 3.85×10^{14} 。图 3 选这列画直方图和经验分位数：前者显示各区间的样本密度，后者不受直方图区间边界影响，便于确认上尾何时陡升。两图都显示主体集中在低值区、最高分位突然上升。直方图横轴采用 $\log_{10}$ 仅为了显示尺度，实验输入仍按各模型的训练流程处理。




图 3: Ipc 的分组直方图与分位数曲线。右图纵轴为对数刻度，尾部陡升表明少数极大值会主导原尺度的平均数。

这样的分布启发我们检查 RRL 的切点：若随机切点落在样本稀少的区间，规则很难利用它。后续实验把当前训练集的经验分位数切点作为候选，与原始随机切点配对比较。

1.3 DIA: 单列信号与整体相关性

最后检查两个问题：单列能提供多少线性信号，输入列之间又重复了多少信息。为此计算 Pearson 相关系数 r ，其正负表示同向或反向变化，绝对值越接近 1，线性联系越强。179 个非常量描述符中，最大的标签相关 $|r|$ 约为 0.216；图 4 右侧展示最靠前的八列，数值仍不大。这与分组箱线图的重叠相呼应。左侧把全部 $\binom{179}{2} = 15931$ 对描述符的 $|r|$ 汇总：中位数为 0.068，但有 101 对达到 0.95。整体以低相关为主，局部又存在几乎重复的测量。我们保留全部描述符，让规则模型学习组合条件；删除高相关列可作为后续更精简模型的实验方向。




图 4: DIA 全部描述符对的相关强度分布，以及与标签相关性最大的八列。虚线标出 $|r| = 0.95$ ；右图保留相关系数正负方向。

相关系数的分布能概括全局，却看不出强相关集中在哪些列。图 5 因此把两种尺度放在一起：左侧选标签与七列代表性描述符，保留名称和格内系数；右侧展示全部 179 列非常量描述符的 179×179 矩阵，按原始字段顺序排列，用颜色查看整体，不标密集的行列名称。右图大部分区域颜色较浅，夹杂少数较深的条带和小块；左图进一步指出 fr_aniline 与 SlogP_VSA10 的 $r \approx 0.72$ 、PEOE_VSA2 与 fr_C_0 的 $r \approx 0.69$ 。标签行的系数仍较弱，支持后续尝试组合条件。




图 5: DIA 的局部与全局 Pearson 相关热力图。左: 标签与七列描述符, 格内标出系数; 右: 179 个非常量描述符的完整矩阵, 不标行列名称。两图共用色标, 蓝绿色为正相关、珊瑚红为负相关。

1.4 Abalone: 目标、测量质量与分组结构

先算环数的中心和离散程度, 再画图 6, 是为了知道模型通常要预测什么范围, 以及稀少的高环数会不会被整体误差掩盖。环数的均值为 9.934、中位数和众数均为 9、标准差为 3.224; 左侧直方图显示大部分样本集中在中间, Rings ≥ 20 仅 62 条 (1.48%)。右侧按 Sex 分组画箱线图, 用同一尺度比较各组中位数和中间 50% 的范围: F、I、M 三组平均环数分别为 11.129、7.890、10.705, I 幼体整体偏低。Sex 是类别而非自然顺序, 输入模型时采用 One-Hot 编码; 高环数则需要单独报告误差。




图 6: Abalone 环数直方图与按 Sex 分组的箱线图。红色浅区对应环数至少 20 的少数样本; 箱体展示各组中间 50% 的环数。

目标之外, 还需知道七项输入通常落在什么范围、尾部有多长。表 1 因此逐列计算中位数和四分位距 (表示中间一半数据的典型尺度), 同时保留最小值、最大值和偏度来检查两端。偏度为正表示右侧尾巴较长, 为负表示左侧尾巴较长。Length、Diameter 略向左偏, 各重量字段中度右偏; Height 的偏度达到 3.129, 与最大值 1.130 远离中位数 0.140 相吻合。数值字段的典型尺度也不同, 因此线性基线的标准化参数只从训练折估计; 后面再单独核查极端高度。

表 1: Abalone 七项数值输入的全数据描述统计；四分位距 $IQR = Q_3 - Q_1$

字段	最小值	中位数	IQR	最大值	偏度
Length	0.075	0.545	0.165	0.815	-0.640
Diameter	0.055	0.425	0.130	0.650	-0.609
Height	0.000	0.140	0.050	1.130	3.129
Whole weight	0.002	0.800	0.712	2.826	0.531
Shucked weight	0.001	0.336	0.316	1.488	0.719
Viscera weight	0.000	0.171	0.159	0.760	0.592
Shell weight	0.002	0.234	0.199	1.005	0.621

Sex 三组的环数不同，也可能伴随尺寸差异。为了看清这一点，图 7 从七项输入中各选一个代表：尺寸用 Length，重量用 Shell weight，分别画分组箱线图。I 组的壳长中位数为 0.435，F、M 为 0.590、0.580；壳重中位数为 0.113，F、M 为 0.295、0.276。I 组在目标和两项测量上都偏低，说明分组信息与连续尺寸信息有关联；后续用 One-Hot 表示组别，让模型结合具体尺寸学习预测。




图 7: Abalone 两项代表性输入按 Sex 分组的箱线图。左为壳长，右为壳重；箱体与须展示各组主体范围，绘图时隐藏离群点以便比较中位数。

直方图的形状会受分箱宽度影响，箱线图又只显示几个关键位置。为了核对完整的上尾和组间差异，图 8 把观测值从小到大排序，画出每个分位点的环数，以及全体高度的分位数。左图中幼体 I 的环数曲线整体低于 F、M，尤其第 95 百分位数约为 13 环，而 F、M 分别约为 17.7、17 环；这进一步说明分组差异贯穿分布，而高环数主要在尾端。右图显示 99% 的高度不超过 0.22，最大值却达到 1.13，值得回到原始记录检查。




图 8: Abalone 的经验分位数曲线。左：按 Sex 分组的环数；右：全体高度，红点标出第 99 百分位数及最大值。

分位数指出极端值，两个测量字段的散点关系则能发现更具体的矛盾：高度应低于最长壳长，各部分重量应低于整体重量。按这些关系核查后，图 9 标出 7 条疑点：高度为零 2 条、高度大于最长壳长 1 条、去壳肉重超过整体重量 4 条；另有一条壳重超过整体重量，与高度为零的记录重合。左图红点对应高度疑点，右图红点对应肉重疑点。主实验保留原记录，并在训练折上检查剔除疑点的敏感性。按 $1.5IQR$ 标出的统计离群点数量更多，既有稀有但可信的高环数个体，也有值得复核的测量值；两者在分析中分别处理。




图 9: Abalone 测量关系与 7 条疑点。红点为不符合简单测量约束的记录，虚线表示两测量值相等；右图放大低重量区域，以便查看四条肉重大于整体重的记录。

1.5 Abalone: 共线性与非线性趋势

先看单条记录而非组均值，才能知道同一重量实际对应多宽的环数范围。图 10 因此并排画出壳重和去壳肉重对环数的原始散点，透明度较低，重叠较多的地方颜色更深。壳重与环数的上升关系较清楚，去壳肉重的点云更散；以左图阴影标出的壳重 $[0.2, 0.3]$ 为例，共有 1067 条记录，环数第 10 至 90 百分位数仍从 8 跨到 14，完整范围为 6–23。重量有预测价值，但只看这一重量仍难以精确预测每条记录的环数。




图 10: Abalone 单条记录的重量与环数关系。左图阴影为壳重 $[0.2, 0.3]$ 的样本带；标题中的 r 为 Pearson 相关系数。

散点显示样本级波动；为了汇总七项测量之间的重复信息，以及它们各自与环数的线性联系，图 11 再计算七项数值输入与环数的 8×8 Pearson 相关矩阵。Length 与 Diameter 的 $r = 0.987$ ，整体重量与去壳肉重的 $r = 0.969$ ，两组输入存在明显共线性；环数与壳重的相关约 0.628，却与去壳肉重只有约 0.421，说明不同重量字段提供的年龄信息并不相同。强共线性会让普通线性回归的单个系数容易随样本变化，因而给线性基线加上 L2 惩罚，形成 Ridge 回归。壳重与环数的 Spearman 秩相关约 0.692，高于 Pearson 的约 0.628，提示上升趋势较明确，曲线形状还值得进一步检查。




图 11: Abalone 数值字段的 Pearson 相关矩阵。格内数字为相关系数；两组尺寸/重量输入之间形成明显的高相关区域。

原始散点显示波动范围，还需归纳曲线是否有平台。图 12 在每个 Sex 组内把去壳肉重、壳重各分为约八个等频箱，每个点是该箱的平均重量和平均环数。等频分箱让各点由数量相近的样本支撑，也比数千个原始散点更容易看出走向。幼体通常位于较低环数；成年组的肉重曲线后段趋缓，壳重则较稳定地上升。同一重量附近的环数仍会波动，尺寸只能解释部分年龄差异。这一观察支持把能表示阈值和交互的随机森林、RRL 与线性基线并列比较；也提醒我们纯二值规则做回归时可能损失区间内部的连续变化。




图 12: 按 Sex 分组的条件分箱趋势。每条线只根据相应组的一个测量字段分箱；点为箱内平均环数。

1.6 实际采用的预处理

需要标准化的输入只在当前训练子集估计均值和标准差，再把同一参数用于验证或测试子集；Abalone 的目标缩放也按此方式处理，预测时还原为环数。随机森林使用原量纲。RRL 所需的 .data、.info 文件由数据准备脚本生成。

表 2: 从观察到实验处理的对应关系

任务	数据观察	处理与验证
DIA	阳性约四分之一	分层五折；报告 Accuracy、Macro-F1 与阳性 P/R/F1
DIA	零值与极长右尾共存	比较随机切点和训练折分位数切点
DIA	局部描述符高度相关	原始、优化 RRL 共用 196 列输入，保证结构实验可比
Abalone	Sex 为无序类别	One-Hot 编码，与七项数值测量共同输入
Abalone	数值字段尺度与尾部不同	Ridge 在训练折内标准化；RF 使用原量纲
Abalone	尺寸/重量共线，趋势有弯曲	Ridge 控制线性系数，RF 与 RRL 学阈值及交互
Abalone	7 条疑点、62 条高环数	主实验保留原始记录；做训练内敏感性及尾部误差检查

2 模型训练

2.1 三种模型如何做预测

设一个样本的输入为 $x_i = (x_{i1}, \dots, x_{id})$ ，真实标签或环数为 y_i ，样本数为 n 。三个模型使用同一任务的同一训练/测试索引，区别在于怎样把输入映射为预测值。

手写线性模型。DIA 使用逻辑回归。先计算线性分数 $z_i = w^\top x_i + b$ ，再经 sigmoid 得到阳性概率

$$p_i = P(y_i = 1 | x_i) = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}. \quad (1)$$

w_j 表示第 j 个标准化输入增加一个单位时，阳性对数几率 $\log[p/(1-p)]$ 的变化； b 是截距。令 $y_i \in \{0, 1\}$ ，真实类别的概率为 $p_i^{y_i} (1 - p_i)^{1-y_i}$ 。让全部训练样本的这一概率尽量大，等价于最小化负对数似然，并给系数加 L2 惩罚：

$$L_{\log}(w, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] + \frac{\lambda}{2} \|w\|_2^2. \quad (2)$$

由 $\partial \sigma(z)/\partial z = \sigma(z)[1 - \sigma(z)]$ 和链式法则，可得 $\nabla_w L_{\log} = X^\top (p - y)/n + \lambda w$ 、 $\partial L_{\log}/\partial b = \sum_i (p_i - y_i)/n$ 。项目中的 NumPy 实现按此梯度逐轮更新 w, b ，预测时以 $p_i \geq 0.5$ 判阳性。

Abalone 使用 Ridge 回归： $\hat{y}_i = w^\top x_i + b$ ，输出直接是预计环数。令 $\tilde{X} = [\mathbf{1}, X]$ 、 $\beta = (b, w^\top)^\top$ 、 $D = \text{diag}(0, 1, \dots, 1)$ ，训练目标为

$$L_{\text{ridge}}(\beta) = \frac{1}{n} \|y - \tilde{X}\beta\|_2^2 + \lambda \beta^\top D \beta. \quad (3)$$

对 β 求导并令其为零，得到

$$(\tilde{X}^\top \tilde{X} + n\lambda D)\hat{\beta} = \tilde{X}^\top y. \quad (4)$$

截距在 D 中对应 0，保持不受惩罚；其余系数被适度收缩，有助于处理尺寸和重量的共线性。项目用 NumPy 求解式 (4)，没有调用现成 Ridge 或逻辑回归估计器。逻辑回归与 Ridge 都给出简洁的加性预测，复杂交互则需要额外构造特征。

随机森林。一棵决策树反复问“某个字段是否小于阈值”，把样本划入叶节点。DIA 树选择让子节点类别更纯的切分：若节点中阳性比例为 q ，Gini 不纯度为

$$G(q) = 1 - q^2 - (1 - q)^2 = 2q(1 - q). \quad (5)$$

例如 $q = 0.5$ 时两类混杂， $G = 0.5$ ；若节点只有一种类别， $G = 0$ 。切分成左右子节点时，选择使 $G(q) - \frac{n_L}{n_P}G(q_L) - \frac{n_R}{n_P}G(q_R)$ 最大的阈值，其中 n_P, n_L, n_R 是父节点与两个子节点的样本数。Abalone 树把 G 换成节点内平均平方偏差 $|S|^{-1} \sum_{i \in S} (y_i - \bar{y}_S)^2$ ，叶节点输出训练样本的平均环数。森林对训练数据有放回抽样生成多棵树，并在各切分点只考虑一部分输入字段；分类把各树的阳性概率平均，回归把各树的环数预测平均：

$$\hat{p}_{\text{RF}}(x) = \frac{1}{B} \sum_{t=1}^B p_t(x), \quad \hat{y}_{\text{RF}}(x) = \frac{1}{B} \sum_{t=1}^B \hat{y}_t(x). \quad (6)$$

B 是树的数量。不同树对样本和字段的选择有所不同，平均后预测更稳定；树还能自然组合多个阈值。实验采用 scikit-learn 的随机森林，与前述手写线性基线形成不同复杂度的参照。

RRL 规则表征学习器。 RRL[1] 先把输入变成真假条件，例如 $u_1 = \mathbf{1}[\text{MolMR} > 90]$ 、 $u_2 = \mathbf{1}[\text{TPSA} \leq 100]$ 。对每个连续阈值同时提供“大于”和“小于等于”两个条件，使逻辑层可以直接选用任一方向。逻辑层有 AND 与 OR 节点；令 $h_{kj} = \mathbf{1}[W_{kj} > 0.5]$ 表示节点 j 是否选择条件 k ，则严格的离散输出为

$$R_j^\wedge(u) = \mathbf{1}\left[\sum_k h_{kj}(1 - u_k) = 0\right], \quad R_j^\vee(u) = \mathbf{1}\left[\sum_k h_{kj}u_k > 0\right]. \quad (7)$$

前式要求所有已选条件成立，后式要求至少一个已选条件成立。多层逻辑可以把已有规则继续组合。最后的输出层把规则激活 $R_j(x) \in \{0, 1\}$ 加权求和。DIA 为阴性、阳性各计算一个分数 (logit) $z_c = b_c + \sum_j a_{cj}R_j(x)$ ，再以

$$P(y = c | x) = \frac{e^{z_c}}{e^{z_0} + e^{z_1}} \quad (8)$$

得到两类概率。训练时对 logits 除以可学习的正温度 $T = e^t$ 再计算交叉熵；温度改变梯度和概率尖锐程度，正值缩放保持类别排序。规则 R_j 成立时， $a_{1j} - a_{0j}$ 为正表示它相对支持阳性。Abalone 把输出改为一个实数 $\hat{y} = b + \sum_j a_j R_j(x)$ ，并将损失改成 $L_{\text{MSE}} = \sum_i (\hat{y}_i - y_i)^2 / n$ ；例如某条规则成立且 $a_j = -0.14$ ，它给最终预测减少约 0.14 环。所有激活规则与截距一起决定预测，回归输出保持连续值。

式 (7) 的 0/1 连接难以直接求导。RRL 的训练保留这套严格离散前向，同时用连续代理为连接参数提供更新方向。其 NLAF（新型逻辑激活函数）可写为

$$\mathcal{G}(t) = 1 - \frac{1}{1 - (\alpha t)^\beta}, \quad \mathcal{P}(s) = (1 - s)^{-\gamma}, \quad (9)$$

$$\tilde{R}^\wedge = \mathcal{P}\left(-\sum_k \mathcal{G}(1 - u_k)\mathcal{G}(W_{kj})\right), \quad \tilde{R}^\vee = 1 - \mathcal{P}\left(-\sum_k \mathcal{G}(u_k)\mathcal{G}(W_{kj})\right). \quad (10)$$

$\alpha < 1$ 保持数值有限， β, γ 控制曲线形状。对 AND，每个“已选但不成立”的条件向求和项贡献违反证据；对 OR，贡献的是“已选且成立”的证据。这样把高维连乘改为加和，并可用矩阵乘法计算。梯度嫁接在前向返回严格规则值 R ，反向采用连续代理 $\tilde{R}$ 的导数，近似为

$$\nabla_W L \approx \frac{\partial L}{\partial R} \frac{\partial \tilde{R}}{\partial W}. \quad (11)$$

输出层、逻辑连接都通过 Adam 更新，逻辑权重约束在 $[0, 1]$ 。本项目保留原始 AND/OR、NLAF 和梯度嫁接，回归任务改动集中在输出维度与损失函数。

2.2 五折评价、内部验证与指标

DIA 使用随机分层五折，约每折 119–120 条，并尽量维持 24.8% 的阳性比例；Abalone 随机打乱后分为五折，约每折 835–836 条。每轮拿一折当测试折，其余四折用于训练。以 DIA 的第二折为例，第二折暂时不参与均值、标准差、切点、超参数或早停的选择；训练完成后只在它上面评价一次。轮流换五次，每条记录恰好在一轮中成为测试样本。

训练用的四折内部还要选超参数。DIA 线性与森林基线从这四折中再留出 20% 作验证，优化 RRL 使用内部三折；Abalone 三类模型均以内部三折选择主要参数，RRL 需要早停时从相应训练部分再留一小块验证数据。选好参数后在该轮全部四折上重新训练，再测外层测试折。内层回答“用哪套训练配置”，外层回答“这套选择流程遇到未参与选择的样本表现如何”。两任务均固定外层随机种子 0，并复用相同索引比较模型。

DIA 的阳性 Precision、Recall 和 F1 分别为

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}. \quad (12)$$

TP 是找出的真实阳性， FP 是误报， FN 是漏检。Precision 回答“报出的阳性有多少可信”，Recall 回答“真实阳性找回了多少”，F1 同时考虑两者。报告统一以阳性概率 0.5 为分类阈值；调整阈值会改变这三个值。

总体正确率 $Accuracy = (TP + TN)/n$ ，其中 TN 为正确判出的阴性。对阴性也按式 (12) 计算一个 $F1_-$ ，两类取平均得到 $Macro-F1 = (F1_+ + F1_-)/2$ 。Accuracy 告诉我们总体判对多少，Macro-F1 让两类各占一半权重；因此表 4 同时列出二者和阳性 P/R/F1。ROC 与 AP 用于更完整的阈值分析，本报告主表聚焦固定阈值下的分类表现。

Abalone 用原始环数计算

$$RMSE = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}, \quad MAE = \frac{1}{n} \sum_i |\hat{y}_i - y_i|, \quad R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (y_i - \bar{y})^2}. \quad (13)$$

RMSE 对大错更敏感，MAE 更接近“平均差几环”， R^2 表示相对于本折直接预测均值的改善。内层按 RMSE 选参，此外单独检查环数至少 20 的样本，以观察稀少高值上的误差。

2.3 初版训练结果

DIA 原始 RRL 采用随机切点、5@16 结构（每个连续字段五个切点，每类逻辑节点各 16 个）、学习率 0.002、batch 32、训练 100 轮。手写逻辑回归比较四档 L2 强度；森林使用 300 棵树，比较三档深度与两档最小叶样本数。外层五折阳性 F1：逻辑回归 0.465、森林 0.503、原始 RRL 0.463。原版规则能提供可执行的条件说明，但性能仍有提升空间。

Abalone 原始 RRL 同样从 5@16 出发，改用单实数输出与 MSE，batch 128、训练 100 轮。Ridge 搜索五档正则强度；首轮森林使用 150 棵树，比较深度与最小叶样本数。训练均值预测的 RMSE 为 3.224 环，原始 RRL 为 2.473，Ridge 为 2.224，森林为 2.147。规则明显优于常数预测，却落后两个基线；下一节围绕 EDA 和误差现象逐轮调整。

3 模型结构优化

3.1 DIA: 先验证切点，再联合选择配置

图 3 显示 DIA 描述符的取值并不均匀：一些列大量为零，Ipc 等列还有很长的右尾。原始 RRL 随机生成切点，可能把一些切点放在样本稀少的区间。我们先只改这一处：对每个连续字段，改用当前训练子集的五经验分位点，规则结构和训练参数保持原样：

$$c_{jk} = Q_{X_j}^{\text{train}}(k/6), \quad k = 1, \dots, 5. \quad (14)$$

c_{jk} 是第 j 个字段从小到大排序后的第 $k/6$ 分位点；切点只由训练数据计算。原始 RRL 的阳性 Recall/F1 为 0.418/0.463，分位数版升至 0.467/0.480。这一步说明按实际分布设置切点有一定帮助，但单改切点带来的提升较小。

第二步同时考察切点、规则规模和训练方式。我们预先固定 40 套候选配置，涵盖随机、分位数和依据训练标签的 Gini 切点，以及规则宽度与深度、NLAF 参数、学习率、L2、类别权重和训练轮数等。每轮先在外层四折训练数据中再做三折验证，按验证集 PR-AUC 选出一套配置；随后用这四折重新训练，只在留出的外层测试折评价。五轮共完成 $5 \times 40 \times 3 = 600$ 次内部训练和 5 次外层重训，阳性 F1 达到 0.609，Recall 达到 0.541。

3.2 Abalone: 从连续分支的成功回到规则本身

Abalone 的起点是把分类 RRL 改成实数输出和 MSE 损失，保留 AND/OR 规则，得到 RMSE 2.473。第一轮仍只优化纯规则模型：比较 24 组切点、网络结构、损失和训练参数后，RMSE 降至 2.290，但仍高于手写 Ridge 的 2.224 和随机森林的 2.147。扩大搜索也没有消除差距，于是我们开始追问：限制来自规则的训练和输出权重，还是二值条件本身丢掉了回归所需的连续变化？这一轮还核查了两个干扰因素：只在训练折移除 7 条测量疑点，收益并不稳定；分位数切点的早期优势在固定相同权重初值后缩小。因此后续比较保留原记录，并尽量配对初始化。

第二轮分别检查这两种可能。先在规则训练后固定规则，用 Ridge 重新拟合规则的输出权重；本轮纯规则对照达到 2.257，仍未超过 Ridge 基线。图 12 又显示重量与环数有平滑上升和局部趋缓：同一组二值条件覆盖的区间内，数值大小仍可能影响环数。我们便给输出头增加一条并行的连续通路，让原数值表示总体趋势，hinge 项 $\max(0, x - c)$ 表示切点前后斜率的变化，规则补充条件组合：

$$\hat{y} = b + \underbrace{\sum_k v_k x_k + \sum_{k,t} u_{kt} \max(0, x_k - c_{kt})}_{\text{连续分支}} + \underbrace{\sum_j a_j R_j(x)}_{\text{规则分支}}. \quad (15)$$

实现时先训练并固定 RRL 规则，再用 Ridge 联合拟合规则激活、原数值和 hinge 项的输出系数。混合模型的 RMSE 降至 2.145，几乎追平森林；然而用相同连续特征重新拟合、完全去掉规则后，RMSE 进一步降至 2.124。这一对照表明第二轮的主要收益来自连续通路，当时的规则尚未提供额外预测收益。

第三轮的目标因此变得具体：保留连续趋势的优势，同时让规则真正补充它。我们先把森林从原先 6 组扩为 72 组候选，增加树数和特征、样本采样比例等选择；扩搜后的 RMSE 约 2.148，与原版接近。对混合模型，我们考虑第二轮把规则系数和连续系数使用同一个 L2 强度，可能使两类信息互相牵制，于是把惩罚拆成 $\lambda_R \|a\|_2^2 + \lambda_C \|v\|_2^2$ ： a 是规则输出系数， v 汇集原数值、分段线性项和类别编码的系数。规则固定后，两类系数仍用 Ridge 一起拟合。候选还比较了固定训练轮

数与训练内早停、单模型与双种子预测平均，以及先拟合连续部分再让规则学习残差。残差训练没有胜出；入选流程仍让规则直接学习 Rings，再与连续项共同预测。

第三轮混合模型的五折 RMSE 达到 2.103，低于扩搜森林的 2.148。更重要的是，保持每折相同的连续特征与惩罚设置，移除规则并重新拟合输出头后，五折 RMSE 均上升，平均高约 0.022 环。规则这次在连续趋势之外产生了可测的增量；2.103 对应的是分组正则、训练配置选择和双种子平均组成的混合流程。第四轮继续试局部规则斜率、更宽网络和更多成员，RMSE 为 2.106，没有超过第三轮。

这时需要选择报告的主线。混合模型预测更准，但式 (15) 中的连续通路承担了主要预测工作；我们希望检验仅凭学出的规则，RRL 能把回归做到什么程度。第五轮因此移除原数值和 hinge 直连，让预测重新完全由规则激活的加权和给出。沿用训练内早停，并在规则固定后只用其激活值重拟合输出权重；同时比较完整 Sex 编码和短规则初始化。早停的配对收益较明确，后两项没有稳定增益。相对旧纯规则对照的 2.257，两个种子分别达到 2.203、2.205：已经略优于 Ridge 的 2.224，仍落后森林的 2.147。

第六轮继续问如何让这些规则更短、更有信息。分位数切点覆盖取值分布，却未必最能区分不同环数；训练后的规则平均还连着约 10–11 个条件。参考逻辑网络回归与稀疏规则研究 [4, 5]，我们分别尝试用训练内单特征回归树确定切点，以及限制每个节点最多选择八条硬连接。表 3 是固定配置的 2×2 对照：两项合用时，两个种子的 RMSE 小幅下降，平均条件数也降至约 7。

表 3: Abalone 纯规则固定机制实验：两列种子分别训练，数字为外层五折均值

切点与连接方式	RMSE 314	RMSE 2718	条件数 314	条件数 2718
分位数参照	2.2085	2.2043	10.47	11.38
回归树切点	2.1952	2.1969	11.20	10.43
连接上限 8	2.1984	2.1977	7.10	6.91
树切点 + 上限 8	2.1859	2.1952	6.92	7.14

固定对照中的组合策略表现较好，但完整实验仍须按训练内验证结果选模型。把 12 个候选交给内部三折和双种子评分后，外层 RMSE 分别为 2.1942/2.2047；全数据模型固定种子 314，选中较宽的 20@128 和分位数切点，未采用树切点与连接上限。因此表 3 展示的是缩短规则的机制线索，交付模型则代表预定选参流程的结果。回看六轮：连续通路改善了混合预测，匹配消融确认规则也能补充它；回到纯规则后，模型超过简单线性基线，但与森林仍有差距。两条路线分别回答了“怎样预测得更准”和“规则本身能做到什么”。

4 对比分析

4.1 DIA：少数类识别

表 4: DIA 外层五折结果，阈值 0.5；均值 $\pm$ 折间标准差

模型	Accuracy $\uparrow$	Macro-F1 $\uparrow$	阳性 P $\uparrow$	阳性 R $\uparrow$	阳性 F1 $\uparrow$
手写逻辑回归	0.762 ± 0.048	0.656 ± 0.055	0.548 ± 0.159	0.411 ± 0.060	0.465 ± 0.079
随机森林	0.826 ± 0.017	0.699 ± 0.036	0.861 ± 0.080	0.359 ± 0.065	0.503 ± 0.063
原始 RRL	0.760 ± 0.020	0.654 ± 0.034	0.520 ± 0.053	0.418 ± 0.065	0.463 ± 0.057
分位数 RRL	0.754 ± 0.072	0.657 ± 0.056	0.591 ± 0.213	0.467 ± 0.167	0.480 ± 0.082
联合优化 RRL	0.828 ± 0.029	0.749 ± 0.041	0.696 ± 0.066	0.541 ± 0.063	0.609 ± 0.063

优化 RRL 与森林的 Accuracy 约为 0.828 和 0.826，几乎持平；Macro-F1 则为 0.749 和 0.699，说明前者对两类的表现更均衡。森林报出的阳性最可信，Precision 为 0.861；优化 RRL 找回的阳性最多，Recall 为 0.541，并以 0.609 获得最高阳性 F1。这个差别很直观：森林更保守，规则模型在当前阈值下更愿意报阳性。DIA 的风险筛查更关注漏检时，RRL 的取舍较有吸引力；若误报成本高，则森林值得优先考虑。最终部署仍需按真实成本选择阈值。

4.2 Abalone：精度与高环数误差

表 5: Abalone 外层五折结果；误差单位为环，均值 $\pm$ 折间标准差

模型	RMSE $\downarrow$	MAE $\downarrow$	R^2 $\uparrow$	≥ 20 MAE $\downarrow$
训练均值	3.224 ± 0.122	2.364 ± 0.097	-0.003 ± 0.004	11.692 ± 0.684
手写 Ridge	2.224 ± 0.136	1.587 ± 0.069	0.522 ± 0.038	7.170 ± 0.718
随机森林	2.147 ± 0.039	1.514 ± 0.024	0.554 ± 0.028	7.386 ± 0.632
原始回归 RRL	2.473 ± 0.216	1.756 ± 0.148	0.409 ± 0.072	8.960 ± 1.185
首轮优化 RRL	2.290 ± 0.055	1.634 ± 0.062	0.493 ± 0.015	8.363 ± 0.613
纯规则 RRL，种子 314	2.194 ± 0.072	1.557 ± 0.041	0.535 ± 0.015	7.805 ± 0.655
纯规则 RRL，种子 2718	2.205 ± 0.072	1.563 ± 0.049	0.530 ± 0.023	8.000 ± 0.848

纯规则 RRL 从 2.473 逐步降至约 2.20 环，两种种子都略好于普通 Ridge；森林在总体 RMSE、MAE、 R^2 上仍领先。图 10 中同一重量对应较宽的环数，也解释了为什么三种模型都会留下回归误差。高环数子集呈另一种排序：Ridge 的 MAE 最低。该子集只有 62 条，五折各次测试样本更少，因此将它作为误差诊断，与总体结论并列呈现。混合连续分支曾达到 2.103，但那是另一套模型结构，表 5 保留纯规则主线的可比成绩。

4.3 规则是否真的可读、是否忠实

线性模型的参数最少，单个系数容易查看；森林由大量树共同投票，查看某棵树只能解释整体决策的一部分。RRL 的规则直接对应模型执行的条件。比如 Abalone 最终模型中一条规则同时要求 $\text{Length} > 0.605$ 、 $\text{Viscera weight} > 0.089$ 、 $\text{Height} \leq 0.2$ 和 $\text{Whole weight} \leq 1.712$ ，输出权

重约 -0.141 环。它在训练数据上的支持度约 0.216，即约 21.6% 的样本满足这些条件；预测还会叠加其他激活规则和截距。

规则数和长度影响阅读成本。DIA 原始 RRL 的五折平均约有 13.8 条简化规则、58.8 条硬连接；优化版约为 69.8 条规则、1806 条硬连接。更多规则提高了阳性 F1，也使整套模型难以在一页纸上读完。Abalone 最终纯规则模型有 256 个原始逻辑节点、2430 条硬连接，平均每节点 9.492 个条件；表 3 的简化机制能进一步缩短规则，值得作为后续折中方案。

我们也核查文字规则与实际计算的一致性。DIA 保存的模型在普通前向与严格离散前向下，对五折测试样本给出相同类别。Abalone 从导出的完整规则 JSON 独立执行 NumPy 布尔计算，和保存预测的最大差约 1.78×10^{-15} 环；全数据模型重载差为零。由此，报告中的规则来自模型实际使用的逻辑结构，性能与解释可追溯到同一次实验。

4.4 结论与复现

DIA 的少数阳性、稀疏长尾和弱单列信号，让切点覆盖和规则组合成为关键；优化 RRL 在阳性 F1 与 Recall 上取得最好结果。Abalone 沿尺寸呈连续变化，森林总体最准确，纯规则 RRL 则在保持可执行规则的同时超过简单 Ridge。Abalone 的探索还给出两个有用的反例：额外连续分支可以显著提高分数，却需用去规则消融检查贡献；较短规则可通过树切点与连接约束得到，但最终选参未必自动偏好它。

数据下载入口是 `download_data.py`。统计和绘图脚本放在 `analysis/`，手写线性模型与 RRL 分别在 `models/manual_glm/`、`models/rrl/`；逐折预测、搜索及规则审计保存在 `results/dia/`、`results/abalone/`。本报告十二张选图由 `analysis/report_figures.py` 重建。小组成员及真实分工须在正式提交前由成员填写。

参考文献

- [1] Z. Wang, W. Zhang, N. Liu, and J. Wang, *Learning Interpretable Rules for Scalable Data Representation and Classification*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(2):1121–1133, 2024. DOI: [10.1109/TPAMI.2023.3328881](https://doi.org/10.1109/TPAMI.2023.3328881).
- [2] X. Huang, *Drug Induced Autoimmunity Prediction*, UCI Machine Learning Repository, 2025. UCI 1104.
- [3] W. Nash, T. Sellers, S. Talbot, A. Cawthorn, and W. Ford, *Abalone*, UCI Machine Learning Repository, 1994. UCI 1.
- [4] C. Yue and N. K. Jha, *Learning Interpretable Differentiable Logic Networks for Tabular Regression*, 2025. [arXiv:2505.23615](https://arxiv.org/abs/2505.23615).
- [5] H. F. Soegeng, S. K. Modi, and T. Peyrin, *TT-Sparse: Learning Sparse Rule Models with Differentiable Truth Tables*, 2026. [arXiv:2603.07606](https://arxiv.org/abs/2603.07606).