

可解释数据挖掘实践：RRL 在分类与回归任务中的应用

数据挖掘课程大作业报告

摘要

本文完成药物诱导自身免疫预测 (DIA) 和鲍鱼环数预测 (Abalone) 两项任务，依次报告数据分析及预处理、模型训练、模型结构优化和对比分析。每项任务都比较手写线性模型、随机森林和规则表征学习器 RRL。DIA 的 597 条记录中阳性占 24.8%，196 个数值描述符兼有稀疏、长尾和局部高度相关的特点；优化后的 RRL 在外层五折获得阳性 F1 0.609，高于随机森林的 0.503。Abalone 的 4177 条记录呈现连续尺寸趋势、强共线性和稀少的高环数样本；纯规则 RRL 的两个训练种子得到 RMSE 2.194、2.205 环，优于 Ridge 的 2.224 环，随机森林仍以 2.147 环领先。逐轮消融说明：DIA 的主要进步来自规则结构与训练配置的联合选择；Abalone 的连续分支虽能改善预测，却会掩盖规则自身的作用，因此最终回到纯规则主线。报告同时检查规则长度、覆盖率及导出规则与实际预测的一致性。

目录

1	数据分析及预处理	1
2	模型训练	5
3	模型结构优化	8
4	对比分析	9

1 数据分析及预处理

1.1 任务与分析方法

课程任务书要求同时完成 DIA 二分类与 Abalone 回归，并从数据分析出发设计预处理和模型实验。DIA[2] 合并官方训练、测试 CSV 后共有 597 条记录；原文件每行包含 Label、SMILES 和 196 个 RDKit 描述符。本文预测 Label，按照任务书不把分子字符串 SMILES 输入模型。Abalone[3] 共有 4177 条记录，以环数 Rings 为目标，输入为 Sex 与七项尺寸、重量测量值；讨论年龄时可用 $\text{Rings} + 1.5$ ，模型直接预测环数。两个数据集均无缺失值。

分析依照课堂介绍的六类工具展开。均值、中位数和众数定位数据中心，标准差及四分位距 $IQR = Q_3 - Q_1$ 描述分散程度；箱线图显示中位数、四分位数和极端观测，直方图显示频数，经验分位数图显示从低到高的取值变化；散点、分箱趋势和相关系数则帮助判断变量间的关系。正文选择能直接解释建模决定的图，完整逐列结果保存在 results/eda/。

1.2 DIA：不平衡、典型分布与长尾

DIA 的阴性 449 条、阳性 148 条，比例约为 3:1。图 1 左侧展示这一比例：即使始终判为阴性，也有约 75.2% 的总体正确率，却找不到一条阳性。因此，后续保持各折类别比例，并重点评价阳性识别。按实际观测值分类，196 个描述符中有 17 列常量、20 列严格 0/1、76 列其他整数、

83 列浮点数。17 列常量不提供区分信息；主实验保留原输入维度，使原版与优化版 RRL 的比较一致。




图 1: DIA 的类别比例与普通数值描述符示例。箱体上下缘为 Q_1, Q_3 ，中线为中位数；两类 MolMR 的主体区域明显重叠。

右侧箱线图来是一列较常见、取值较平稳的参照，说明阳性与阴性的 MolMR 中位数相近；箱线图的须延至 $Q_1 - 1.5IQR, Q_3 + 1.5IQR$ 范围内的实际观测。另一方面，58 列描述符至少 95% 的值为零，Ipc 的中位数约 4.11×10^5 、最大值约 3.85×10^{14} 。图 2 用直方图和经验分位数从两个角度展示这条长尾：主体集中在低值区，最高分位突然上升。直方图横轴采用 $\log_{10}$ 仅为了显示尺度，实验输入仍按各模型的训练流程处理。




图 2: Ipc 的分组直方图与分位数曲线。右图纵轴为对数刻度，尾部陡升表明少数极大值会主导原尺度的平均数。

这样的分布启发我们检查 RRL 的切点：若随机切点落在样本稀少的区间，规则很难利用它。后续实验把当前训练集的经验分位数切点作为候选，与原始随机切点配对比较。

1.3 DIA：单列信号与整体相关性

单列和标签的 Pearson 相关系数刻画线性方向与强度。179 个非常量描述符中，最大的 $|r|$ 约为 0.216；图 3 右侧展示最靠前的八列，数值仍不大。这与分组箱线图的重叠相呼应，提示一个描述符难以独立完成预测。左侧把全部 $\binom{179}{2} = 15931$ 对描述符的 $|r|$ 汇总：中位数为 0.068，但有 101 对达到 0.95。整体以低相关为主，局部又存在几乎重复的测量。我们保留全部描述符，让规则模型学习组合条件；删除高相关列可作为后续更精简模型的实验方向。




图 3: DIA 全部描述符对的相关强度分布, 以及与标签相关性最大的八列。虚线标出 $|r| = 0.95$; 右图保留相关系数正负方向。

1.4 Abalone: 目标、测量质量与分组结构

Abalone 环数的均值为 9.934、中位数和众数均为 9、标准差为 3.224。图 4 显示环数主要集中在中间, 高环数尾部较短: Rings ≥ 20 仅 62 条 (1.48%)。按 Sex 分组, F、I、M 三组平均环数分别为 11.129、7.890、10.705; I 为幼体。Sex 的取值是类别而非自然顺序, 输入模型时采用 One-Hot 编码。




图 4: Abalone 环数直方图与按 Sex 分组的箱线图。红色浅区对应环数至少 20 的少数样本; 箱体展示各组中间 50% 的环数。

对测量值做简单的物理一致性检查, 发现 7 条疑点, 涉及高度为零、高度大于最长壳长、去壳肉重超过整体重量等情形, 其中部分疑点落在同一条记录上。但是现有数据难以恢复正确数值, 主实验保留原记录, 另在训练折上检查剔除疑点的敏感性。箱线图按 $1.5IQR$ 标出的统计离群点数量更多, 既有稀有但可信的高环数个体, 也有值得复核的测量值; 两者在分析中分别处理。

1.5 Abalone: 共线性与非线性趋势

图 5 用一个 8×8 矩阵展示七项数值输入与环数的 Pearson 相关。Length 与 Diameter 的相关系数为 0.987, 整体重量与去壳肉重为 0.969。这类强共线性会让普通线性回归的单个系数容易随样本变化, 因而给线性基线加上 L2 惩罚, 形成 Ridge 回归。壳重与环数的 Spearman 秩相关约 0.692, 高于 Pearson 的约 0.628, 提示关系的上升趋势较明确, 却未必是一条直线。

图 6 把各 Sex 组内部的去壳肉重、壳重各分为约八个等频箱, 点表示箱内平均重量与平均环数。散点在这种汇总下更易读: 幼体通常位于较低环数, 成年组的肉重曲线后段趋缓, 壳重仍较




图 5: Abalone 数值字段的 Pearson 相关矩阵。格内数字为相关系数；两组尺寸/重量输入之间形成明显的高相关区域。

稳定地上升。同一箱内环数还会波动，说明尺寸只能解释部分年龄差异。这一观察支持将能表示阈值和交互的随机森林、RRL 与线性基线并列比较；也提醒我们纯二值规则做回归时可能损失区间内部的连续变化。




图 6: 按 Sex 分组的条件分箱趋势。每条线只根据相应组的一个测量字段分箱；点为箱内平均环数。

1.6 实际采用的预处理

需要标准化的输入只在当前训练子集估计均值和标准差，再把同一参数用于验证或测试子集；Abalone 的目标缩放也按此方式处理，预测时还原为环数。随机森林使用原量纲。RRL 所需的 .data、.info 文件由数据准备脚本生成。

表 1: 从观察到实验处理的对应关系

任务	数据观察	处理与验证
DIA	阳性约四分之一	分层五折；主报阳性 Precision、Recall、F1
DIA	零值与极长右尾共存	比较随机切点和训练折分位数切点
DIA	局部描述符高度相关	原始、优化 RRL 共用 196 列输入，保证结构实验可比
Abalone	Sex 为无序类别	One-Hot 编码，与七项数值测量共同输入
Abalone	尺寸/重量共线，趋势有弯曲	Ridge 控制线性系数，RF 与 RRL 学阈及交互
Abalone	7 条疑点、62 条高环数	主实验保留原始记录；做训练内敏感性及尾部误差检查

2 模型训练

2.1 三种模型如何做预测

设一个样本的输入为 $x_i = (x_{i1}, \dots, x_{id})$ ，真实标签或环数为 y_i ，样本数为 n 。三个模型使用同一任务的同一训练/测试索引，区别在于怎样把输入映射为预测值。

手写线性模型。DIA 使用逻辑回归。先计算线性分数 $z_i = w^\top x_i + b$ ，再经 sigmoid 得到阳性概率

$$p_i = P(y_i = 1 | x_i) = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}. \quad (1)$$

w_j 表示第 j 个标准化输入增加一个单位时，阳性对数几率 $\log[p/(1-p)]$ 的变化； b 是截距。令 $y_i \in \{0, 1\}$ ，真实类别的概率为 $p_i^{y_i}(1-p_i)^{1-y_i}$ 。让全部训练样本的这一概率尽量大，等价于最小化负对数似然，并给系数加 L2 惩罚：

$$L_{\log}(w, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] + \frac{\lambda}{2} \|w\|_2^2. \quad (2)$$

由 $\partial \sigma(z)/\partial z = \sigma(z)[1 - \sigma(z)]$ 和链式法则，可得 $\nabla_w L_{\log} = X^\top(p - y)/n + \lambda w$ 、 $\partial L_{\log}/\partial b = \sum_i (p_i - y_i)/n$ 。项目中的 NumPy 实现按此梯度逐轮更新 w, b ，预测时以 $p_i \geq 0.5$ 判阳性。

Abalone 使用 Ridge 回归： $\hat{y}_i = w^\top x_i + b$ ，输出直接是预计环数。令 $\tilde{X} = [\mathbf{1}, X]$ 、 $\beta = (b, w^\top)^\top$ 、 $D = \text{diag}(0, 1, \dots, 1)$ ，训练目标为

$$L_{\text{ridge}}(\beta) = \frac{1}{n} \|y - \tilde{X}\beta\|_2^2 + \lambda \beta^\top D \beta. \quad (3)$$

对 β 求导并令其为零，得到

$$(\tilde{X}^\top \tilde{X} + n\lambda D)\hat{\beta} = \tilde{X}^\top y. \quad (4)$$

截距在 D 中对应 0，保持不受惩罚；其余系数被适度收缩，有助于处理尺寸和重量的共线性。项目用 NumPy 求解式 (4)，没有调用现成 Ridge 或逻辑回归估计器。逻辑回归与 Ridge 都给出简洁的加性预测，复杂交互则需要额外构造特征。

随机森林。一棵决策树反复问“某个字段是否小于阈值”，把样本划入叶节点。DIA 树选择让子节点类别更纯的切分：若节点中阳性比例为 q ，Gini 不纯度为

$$G(q) = 1 - q^2 - (1 - q)^2 = 2q(1 - q). \quad (5)$$

例如 $q = 0.5$ 时两类混杂， $G = 0.5$ ；若节点只有一种类别， $G = 0$ 。切分成左右子节点时，选择使 $G(q) - \frac{n_L}{n_P}G(q_L) - \frac{n_R}{n_P}G(q_R)$ 最大的阈值，其中 n_P, n_L, n_R 是父节点与两个子节点的样本数。Abalone 树把 G 换成节点内平均平方偏差 $|S|^{-1} \sum_{i \in S} (y_i - \bar{y}_S)^2$ ，叶节点输出训练样本的平均环数。森林对训练数据有放回抽样生成多棵树，并在各切分点只考虑一部分输入字段；分类把各树的阳性概率平均，回归把各树的环数预测平均：

$$\hat{p}_{\text{RF}}(x) = \frac{1}{B} \sum_{t=1}^B p_t(x), \quad \hat{y}_{\text{RF}}(x) = \frac{1}{B} \sum_{t=1}^B \hat{y}_t(x). \quad (6)$$

B 是树的数量。不同树对样本和字段的选择有所不同，平均后预测更稳定；树还能自然组合多个阈值。实验采用 scikit-learn 的随机森林，与前述手写线性基线形成不同复杂度的参照。

RRL 规则表征学习器。 RRL[1] 先把输入变成真假条件，例如 $u_1 = \mathbf{1}[\text{Mo1MR} > 90]$ 、 $u_2 = \mathbf{1}[\text{TPSA} \leq 100]$ 。对每个连续阈值同时提供“大于”和“小于等于”两个条件，使逻辑层可以直接选用任一方向。逻辑层有 AND 与 OR 节点；令 $h_{kj} = \mathbf{1}[W_{kj} > 0.5]$ 表示节点 j 是否选择条件 k ，则严格的离散输出为

$$R_j^\wedge(u) = \mathbf{1} \left[\sum_k h_{kj}(1 - u_k) = 0 \right], \quad R_j^\vee(u) = \mathbf{1} \left[\sum_k h_{kj}u_k > 0 \right]. \quad (7)$$

前式要求所有已选条件成立，后式要求至少一个已选条件成立。多层逻辑可以把已有规则继续组合。最后的输出层把规则激活 $R_j(x) \in \{0, 1\}$ 加权求和。DIA 为阴性、阳性各计算一个分数 (logit) $z_c = b_c + \sum_j a_{cj}R_j(x)$ ，再以

$$P(y = c | x) = \frac{e^{z_c}}{e^{z_0} + e^{z_1}} \quad (8)$$

得到两类概率。训练时对 logits 除以可学习的正温度 $T = e^t$ 再计算交叉熵；温度改变梯度和概率尖锐程度，正值缩放保持类别排序。规则 R_j 成立时， $a_{1j} - a_{0j}$ 为正表示它相对支持阳性。Abalone 把输出改为一个实数 $\hat{y} = b + \sum_j a_j R_j(x)$ ，并将损失改成 $L_{\text{MSE}} = \sum_i (\hat{y}_i - y_i)^2 / n$ ；例如某条规则成立且 $a_j = -0.14$ ，它给最终预测减少约 0.14 环。所有激活规则与截距一起决定预测，回归输出保持连续值。

式 (7) 的 0/1 连接难以直接求导。RRL 的训练保留这套严格离散前向，同时用连续代理为连接参数提供更新方向。其 NLAF（新型逻辑激活函数）可写为

$$\mathcal{G}(t) = 1 - \frac{1}{1 - (\alpha t)^\beta}, \quad \mathcal{P}(s) = (1 - s)^{-\gamma}, \quad (9)$$

$$\tilde{R}^\wedge = \mathcal{P} \left(- \sum_k \mathcal{G}(1 - u_k) \mathcal{G}(W_{kj}) \right), \quad \tilde{R}^\vee = 1 - \mathcal{P} \left(- \sum_k \mathcal{G}(u_k) \mathcal{G}(W_{kj}) \right). \quad (10)$$

$\alpha < 1$ 保持数值有限， β, γ 控制曲线形状。对 AND，每个“已选但不成立”的条件向求和项贡献违反证据；对 OR，贡献的是“已选且成立”的证据。这样把高维连乘改为加和，并可用矩阵乘法计算。梯度嫁接在前向返回严格规则值 R ，反向采用连续代理 $\tilde{R}$ 的导数，近似为

$$\nabla_W L \approx \frac{\partial L}{\partial R} \frac{\partial \tilde{R}}{\partial W}. \quad (11)$$

输出层、逻辑连接都通过 Adam 更新，逻辑权重约束在 $[0, 1]$ 。本项目保留原始 AND/OR、NLAF 和梯度嫁接，回归任务改动集中在输出维度与损失函数。

2.2 五折评价、内部验证与指标

“一折”就是把数据分成五份后的一份。DIA 使用随机分层五折，约每折 119–120 条，并尽量维持 24.8% 的阳性比例；Abalone 随机打乱后分为五折，约每折 835–836 条。每轮拿一折当测试折，其余四折用于训练。以 DIA 的第二折为例，第二折暂时不参与均值、标准差、切点、超参数或早停的选择；训练完成后只在它上面评价一次。轮流换五次，每条记录恰好在一轮中成为测试样本。

训练用的四折内部还要选超参数。DIA 线性与森林基线从这四折中再留出 20% 作验证，优化 RRL 使用内部三折；Abalone 三类模型均以内部三折选择主要参数，RRL 需要早停时从相应训练部分再留一小块验证数据。选好参数后在该轮全部四折上重新训练，再测外层测试折。内层回答“用哪套训练配置”，外层回答“这套选择流程遇到未参与选择的样本表现如何”。两任务均固定外层随机种子 0，并复用相同索引比较模型。

DIA 的阳性 Precision、Recall 和 F1 分别为

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}. \quad (12)$$

TP 是找出的真实性， FP 是误报， FN 是漏检。Precision 回答“报出的阳性有多少可信”，Recall 回答“真实性找回了多少”，F1 同时考虑两者。报告统一以阳性概率 0.5 为分类阈值；调整阈值会改变这三个值。ROC 曲线可跨阈值考察阳性召回与阴性误报率的关系，训练内选参还参考平均精度（AP）；正文以更直接的阳性 P/R/F1 展示最终分类差别。

Abalone 用原始环数计算

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_i |\hat{y}_i - y_i|, \quad R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (y_i - \bar{y})^2}. \quad (13)$$

RMSE 对大错更敏感，MAE 更接近“平均差几环”， R^2 表示相对于本折直接预测均值的改善。内层按 RMSE 选参，此外单独检查环数至少 20 的样本，以观察稀少高值上的误差。

2.3 初版训练结果

DIA 原始 RRL 采用随机切点、5@16 结构（每个连续字段五个切点，每类逻辑节点各 16 个）、学习率 0.002、batch 32、训练 100 轮。手写逻辑回归比较四档 L2 强度；森林使用 300 棵树，比较三档深度与两档最小叶样本数。外层五折阳性 F1：逻辑回归 0.465、森林 0.503、原始 RRL 0.463。原版规则能提供可执行的条件说明，但性能仍有提升空间。

Abalone 原始 RRL 同样从 5@16 出发，改用单实数输出与 MSE，batch 128、训练 100 轮。Ridge 搜索五档正则强度；首轮森林使用 150 棵树，比较深度与最小叶样本数。训练均值预测的 RMSE 为 3.224 环，原始 RRL 为 2.473，Ridge 为 2.224，森林为 2.147。规则明显优于常数预测，却落后两个基线；下一节围绕 EDA 和误差现象逐轮调整。

3 模型结构优化

3.1 DIA：切点与规则容量

许多 DIA 描述符取值集中在零附近，Ipc 等列又有极长右尾。第一项结构实验只把随机阈值替换为当前训练子集的经验分位数：

$$c_{jk} = Q_{X_j}^{\text{train}}(k/6), \quad k = 1, \dots, 5. \quad (14)$$

c_{jk} 是第 j 个连续输入的第 k 个切点。这使五个条件覆盖更多实际观测区间。原始 RRL 的阳性 Recall/F1 为 0.418/0.463，分位数版升至 0.467/0.480。单项改动带来小幅改善，也说明覆盖范围只是问题的一部分。

接着在每个外层训练部分的内部三折比较 40 个固定候选：随机、分位数和训练内标签引导的 Gini 切点，若干规则宽度与深度，以及 NLAf 参数、学习率、L2、类别权重、轮数等。共完成 600 次内部训练、5 次外层重训。优化后阳性 F1 达 0.609，Recall 达 0.541。五个外层折选到的配置并不完全相同，说明结果代表的是“内部选择后重训”的整体流程；分位数单项实验与联合搜索结果分别报告。

3.2 Abalone：从连续分支的成功回到规则本身

第一轮先在纯规则架构内比较 24 组切点、结构、损失和训练参数，RMSE 从 2.473 降至 2.290。分位数切点的早期结果看似更好，之后我们检查随机数消耗，发现不同切点路径会改变后续权重初值；固定相同初始化后，配对结果的改善变小。这个核查让后续结构对照有了更稳固的起点。只在训练折去掉 7 条测量疑点，整体收益也不稳定，主线继续使用全部记录。

第二轮依据图 6 的平滑趋势提出：规则负责区间条件，连续数值通路负责区间内变化。实现上先训练规则并固定，再用 Ridge 一起拟合并规则激活、原数值及 hinge 分段基函数的输出系数：

$$\hat{y} = b + \underbrace{\sum_k v_k x_k + \sum_{k,t} u_{kt} \max(0, x_k - c_{kt})}_{\text{连续分支}} + \underbrace{\sum_j a_j R_j(x)}_{\text{规则分支}}. \quad (15)$$

其中 $\max(0, x - c)$ 在阈值前为零、阈值后线性增长，可以表示趋势斜率变化。混合模型 RMSE 为 2.145，去掉规则的同款连续分支却达到 2.124。这说明该轮提升来自连续部分，推动我们重新检验规则是否真的提供额外信息。

第三轮扩大森林调参范围，同时比较规则与连续系数分组正则、训练早停及先拟合连续部分再用规则拟合残差。胜出的混合配置 RMSE 为 2.103，扩搜森林约 2.148；匹配的去规则消融平均高约 0.022 环，表明这套混合配置中的规则已有边际贡献。残差训练单独并未胜出。第四轮继续加复杂度，也未取得稳定增益。由于连续分支已成为混合模型的主要预测来源，我们把这条路线保留为探索结果，最终模型回到式 (7) 的纯规则输出。

回到规则主线后，我们用训练内早停控制轮数，并在规则固定后仅对规则激活重拟合输出权重；这次不接入原数值。相对旧纯规则 RMSE 2.257，两个种子分别降到 2.203、2.205。随后参考逻辑网络回归和稀疏规则研究 [4, 5]，分别检查回归树切点和每节点最多八条硬连接的上限。固定的 2×2 对照见表 2：组合策略使两个种子的 RMSE 小幅下降，同时把每节点平均条件数从约 10–11 降到约 7。

表 2: Abalone 纯规则固定机制实验；两列种子分别训练，数字为外层五折均值

切点与连接方式	RMSE 314	RMSE 2718	条件数 314	条件数 2718
分位数参照	2.2085	2.2043	10.47	11.38
回归树切点	2.1952	2.1969	11.20	10.43
连接上限 8	2.1984	2.1977	7.10	6.91
树切点 + 上限 8	2.1859	2.1952	6.92	7.14

最后把 12 个候选交给内部三折和双种子选择，外层 RMSE 为 2.1942/2.2047。全数据交付配置选择较宽的 20@128 与分位数切点；表 2 中的树切点 + 连接上限是可读性更好的机制对照，尚未成为交付配置。两条结果线各有意义：前者给出当前完整选参流程的预测表现，后者展示缩短规则的潜力。

4 对比分析

4.1 DIA：少数类识别

表 3: DIA 外层五折结果，阳性类，阈值 0.5；均值 $\pm$ 折间标准差

模型	Precision $\uparrow$	Recall $\uparrow$	F1 $\uparrow$
手写逻辑回归	0.548 $\pm$ 0.159	0.411 $\pm$ 0.060	0.465 $\pm$ 0.079
随机森林	0.861 $\pm$ 0.080	0.359 $\pm$ 0.065	0.503 $\pm$ 0.063
原始 RRL	0.520 $\pm$ 0.053	0.418 $\pm$ 0.065	0.463 $\pm$ 0.057
分位数 RRL	0.591 $\pm$ 0.213	0.467 $\pm$ 0.167	0.480 $\pm$ 0.082
联合优化 RRL	0.696 $\pm$ 0.066	0.541 $\pm$ 0.063	0.609 $\pm$ 0.063

森林报出的阳性最可信，Precision 为 0.861；优化 RRL 找回的阳性最多，Recall 为 0.541，并以 0.609 获得最高 F1。这个差别很直观：森林更保守，规则模型在当前阈值下更愿意报阳性。DIA 的风险筛查更关注漏检时，RRL 的取舍较有吸引力；若误报成本高，则森林值得优先考虑。最终部署仍需按真实成本选择阈值。

4.2 Abalone：精度与高环数误差

纯规则 RRL 从 2.473 逐步降至约 2.20 环，两种种子都略好于普通 Ridge；森林在总体 RMSE、MAE、 R^2 上仍领先。高环数子集呈另一种排序：Ridge 的 MAE 最低。该子集只有 62 条，五折各次测试样本更少，因此将它作为误差诊断，与总体结论并列呈现。混合连续分支曾达到 2.103，但那是另一套模型结构，表 4 保留纯规则主线的可比成绩。

4.3 规则是否真的可读、是否忠实

线性模型的参数最少，单个系数容易查看；森林由大量树共同投票，查看某棵树只能解释整体决策的一部分。RRL 的规则直接对应模型执行的条件。比如 Abalone 最终模型中一条规则同时要求 $\text{Length} > 0.605$ 、 $\text{Viscera weight} > 0.089$ 、 $\text{Height} \leq 0.2$ 和 $\text{Whole weight} \leq 1.712$ ，输出权

表 4: Abalone 外层五折结果；误差单位为环，均值 $\pm$ 折间标准差

模型	RMSE $\downarrow$	MAE $\downarrow$	R^2 $\uparrow$	≥ 20 MAE $\downarrow$
训练均值	3.224 ± 0.122	2.364 ± 0.097	-0.003 ± 0.004	11.692 ± 0.684
手写 Ridge	2.224 ± 0.136	1.587 ± 0.069	0.522 ± 0.038	7.170 ± 0.718
随机森林	2.147 ± 0.039	1.514 ± 0.024	0.554 ± 0.028	7.386 ± 0.632
原始回归 RRL	2.473 ± 0.216	1.756 ± 0.148	0.409 ± 0.072	8.960 ± 1.185
首轮优化 RRL	2.290 ± 0.055	1.634 ± 0.062	0.493 ± 0.015	8.363 ± 0.613
纯规则 RRL, 种子 314	2.194 ± 0.072	1.557 ± 0.041	0.535 ± 0.015	7.805 ± 0.655
纯规则 RRL, 种子 2718	2.205 ± 0.072	1.563 ± 0.049	0.530 ± 0.023	8.000 ± 0.848

重约 -0.141 环。它在训练数据上的支持度约 0.216，即约 21.6% 的样本满足这些条件；预测还会叠加其他激活规则和截距。

规则数和长度影响阅读成本。DIA 原始 RRL 的五折平均约有 13.8 条简化规则、58.8 条硬连接；优化版约为 69.8 条规则、1806 条硬连接。更多规则提高了阳性 F1，也使整套模型难以在一页纸上读完。Abalone 最终纯规则模型有 256 个原始逻辑节点、2430 条硬连接，平均每节点 9.492 个条件；表 2 的简化机制能进一步缩短规则，值得作为后续折中方案。

我们也核查文字规则与实际计算的一致性。DIA 保存的模型在普通前向与严格离散前向下，对五折测试样本给出相同类别。Abalone 从导出的完整规则 JSON 独立执行 NumPy 布尔计算，和保存预测的最大差约 1.78×10^{-15} 环；全数据模型重载差为零。由此，报告中的规则来自模型实际使用的逻辑结构，性能与解释可追溯到同一次实验。

4.4 结论与复现

DIA 的少数阳性、稀疏长尾和弱单列信号，让切点覆盖和规则组合成为关键；优化 RRL 在阳性 F1 与 Recall 上取得最好结果。Abalone 沿尺寸呈连续变化，森林总体最准确，纯规则 RRL 则在保持可执行规则的同时超过简单 Ridge。Abalone 的探索还给出两个有用的反例：额外连续分支可以显著提高分数，却需用去规则消融检查贡献；较短规则可通过树切点与连接约束得到，但最终选参未必自动偏好它。

数据下载入口是 `download_data.py`。统计和绘图脚本放在 `analysis/`，手写线性模型与 RRL 分别在 `models/manual_glm/`、`models/rrl/`；逐折预测、搜索及规则审计保存在 `results/dia/`、`results/abalone/`。本报告六张选图由 `analysis/report_figures.py` 重建。小组成员及真实分工须在正式提交前由成员填写。

参考文献

- [1] Z. Wang, W. Zhang, N. Liu, and J. Wang, *Learning Interpretable Rules for Scalable Data Representation and Classification*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(2):1121–1133, 2024. DOI: [10.1109/TPAMI.2023.3328881](https://doi.org/10.1109/TPAMI.2023.3328881).
- [2] X. Huang, *Drug Induced Autoimmunity Prediction*, UCI Machine Learning Repository, 2025. UCI 1104.
- [3] W. Nash, T. Sellers, S. Talbot, A. Cawthorn, and W. Ford, *Abalone*, UCI Machine Learning Repository, 1994. UCI 1.
- [4] C. Yue and N. K. Jha, *Learning Interpretable Differentiable Logic Networks for Tabular Regression*, 2025. [arXiv:2505.23615](https://arxiv.org/abs/2505.23615).
- [5] H. F. Soegeng, S. K. Modi, and T. Peyrin, *TT-Sparse: Learning Sparse Rule Models with Differentiable Truth Tables*, 2026. [arXiv:2603.07606](https://arxiv.org/abs/2603.07606).